

Consultoría estratégica: Crímenes Violentos

Data Solutions

Consultoría Propuesta

Uno de los aspectos que más preocupan a los ciudadanos, es su seguridad. Queremos ser capaces de poder ir por donde queramos, cuando queramos, sin que haya riesgo de que alguien salga perjudicado. Es por este motivo que presentamos una base de datos dedicada a los crímenes violentos, y el estudio de sus posibles causas. Dicha base de datos es “Communities and Crime”¹.

La elección de esta base de datos se justifica plenamente debido a que recopila datos reales del censo estadounidense de 1990, el informe de crímenes reportados del FBI de 1995 y del estudio de estadísticas administrativas y del uso de la ley de 1990. Esta base de datos fue creada por Michael Redmon.

Además, es de alto valor para el cliente porque traduce toda la complejidad numérica en decisiones estratégicas claras. Al identificar que factores tienen un impacto real en los crímenes violentos, el cliente podrá optimizar su inversión en recursos y predecir el efecto de futuras políticas socioeconómicas.

Estudio de las variables

Visualización preliminar

Antes de profundizar en el código, debemos hacer un análisis preliminar de nuestras variables, esto nos permitirá seleccionar un subconjunto de mayor interés de las mismas.

```
library(knitr)
library(kableExtra)
```

```
## Warning: package 'kableExtra' was built under R version 4.5.3
```

```
library(dplyr)
```

```
##
```

```
## Adjuntando el paquete: 'dplyr'
```

```
## The following object is masked from 'package:kableExtra':
```

```
##
```

```
##      group_rows
```

```
## The following objects are masked from 'package:stats':
```

```
##
```

```
##      filter, lag
```

¹Enlace de Referencia: <https://archive.ics.uci.edu/dataset/183/communities+and+crime>

```
## The following objects are masked from 'package:base':  
##  
## intersect, setdiff, setequal, union
```

```
library(purrr)  
  
#Leemos el archivo .names para extraer los nombres de las columnas  
lineas_texto <- readLines("communities.names")  
  
#Buscamos las líneas que contienen "@attribute"  
lineas_atributos <- grep("@attribute", lineas_texto, value = TRUE)  
  
#Limpiamos el texto para quedarnos solo con el nombre de la variable  
#Esto quita la palabra "@attribute" y el tipo de dato (numeric, string, etc.)  
nombres_columnas <- gsub("@attribute ", "", lineas_atributos)  
nombres_columnas <- gsub(" .*", "", nombres_columnas)  
  
#Cargamos el archivo de datos  
datos <- read.csv("communities.data", header = FALSE, na.strings = "?")  
  
colnames(datos) <- nombres_columnas  
  
#Ahora lo mostramos de forma bonita  
resumen_integral <- datos %>%  
  map_df(~ {  
    es_num <- is.numeric(.x)  
    data.frame(  
      Tipo = class(.x)[1],  
      Primeras_3_Obs = paste(head(.x, 3), collapse = " | "),  
      NAs = sum(is.na(.x))  
    )  
  }, .id = "Variable")  
  
resumen_integral[is.na(resumen_integral)] <- "--"  
  
resumen_integral <- head(resumen_integral, 10)  
  
kable(resumen_integral, format = "latex", align = "c", row.names = FALSE,  
  caption = "Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)") %>%  
  kable_styling(latex_options = c("striped", "repeat_header"), full_width = FALSE) %>%  
  row_spec(0, bold = TRUE, color = "white", background = "#2C3E50") %>%  
  column_spec(1, bold = TRUE) %>%  
  column_spec(2, color = "#E67E22", bold = TRUE) %>%  
  column_spec(3, italic = TRUE)
```

Debido a la gran dimensionalidad del conjunto de datos (128 variables), el análisis exploratorio integral se ha exportado a un documento externo para facilitar la lectura².

²Haz clic aquí para visualizar el resumen completo de las variables: https://drive.google.com/file/d/1WrsFtFY3zNsvuFvzZ2tWkxx_d-aRj-G2/view?usp=sharing

Table 1: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Primeras_3_Obs	NAs
state	integer	8 / 53 / 24	0
county	integer	NA / NA / NA	1174
community	integer	NA / NA / NA	1177
communityname	character	Lakewoodcity / Tukwilacity / Aberdeentown	0
fold	integer	1 / 1 / 1	0
population	numeric	0.19 / 0 / 0	0
householdsize	numeric	0.33 / 0.16 / 0.42	0
racepctblack	numeric	0.02 / 0.12 / 0.49	0
racePctWhite	numeric	0.9 / 0.74 / 0.56	0
racePctAsian	numeric	0.12 / 0.45 / 0.17	0

Información Variables y Justificación de Elección

En la tabla anterior, podemos ver un resumen de cada variable, así como unas primeras observaciones y el tipo de dato.

Debido al alto número de variables, hemos seleccionado un subconjunto de 18 variables, que creemos serán de mayor interés para el estudio.

A continuación, presento la información detallada de cada una:

Variable Dependiente (Objetivo)

- **ViolentCrimesPerPop:** Número total de crímenes violentos por cada cien mil habitantes. Esta es nuestra variable de mayor interés.

Variables Explicativas

Variables Identificadoras

- **county:** Código numérico por condado (Esta no es predictiva pero nos sirve para un estudio más denso o detectar motivos ocultos).

Variables del Uso de la Ley

- **LemasPctOfficDrugUn:** Porcentaje de oficiales asignados a la unidad de drogas. Nos interesa mucho, pues las drogas causan relaciones violentas en los individuos.
- **PolicOperBudg:** Presupuesto operativo de la policía. Muy interesante, pues es veremos si más policías significan menos crímenes.
- **PolicAveOTWorked:** Media de tiempo extra (o fuera de horario de contrato) trabajado.
- **LemasTotReqPerPop:** Total de veces que se ha solicitado a la policía por cada cien mil personas.
- **LemasSwFTPerPop:** Número de oficiales de la policia por cada cien mil habitantes.

Variables de Situación Familiar

- **MalePctDivorce:** Porcentaje de individuos de género masculino que están divorciados. A veces los divorcios se realizan debido a situaciones violentas por parte del hombre.
- **FemalePctDiv:** Porcentaje de individuos de género femenino que están divorciadas.
- **TotalPctDiv:** Porcentaje de la población que está divorciada. Muchas de las situaciones violentas resultan en divorcio, es muy importante.
- **PctKids2Par:** Porcentaje de niños que viven con sus dos padres. Esta variable puede presentar una correlación negativa con la variable dependiente, ya que a mejor situación familiar, menor riesgo hay de tensiones en la familia que desemboquen en violencia doméstica..
- **PctTeen2Par:** Porcentaje de niños de 12-17 años de edad que viven conjuntamente con sus padres (en la misma casa).

Variables Económicas

En general todas las siguientes creemos que influyen, pues normalmente, cuanto peor es la situación económica, más probabilidad hay de infelicidad y violencia, aunque lo analizaremos más adelante.

- **medIncome:** Mediana de las ganancias por hogar.
- **PctPopUnderPov:** Porcentaje de personas por debajo de el nivel de pobreza.
- **PctUnemployed:** Porcentaje de personas de 16 años o más, en trabajos forzados o desempleados.
- **RentLowQ:** Cuartil 25 del coste de la renta.
- **MedRent:** Mediana de la renta bruta.

Variables Sociales

- **PctRecentImmig:** Porcentaje de la población que ha inmigrado en los últimos 3 años. En algunas ocasiones, puede influir el descontento o choque de culturas al principio.
- **NumStreet:** Número de personas sin hogar contadas en las calles. Muy importante para nuestro estudio.

Todas las variables presentadas son numéricas, el dataset no contiene variables categóricas de interés con las que construir un modelo anova o ancova tras nuestro regresión múltiple lineal.

Objetivo del estudio

El objetivo principal es predecir el número de crímenes violentos por cada cien mil habitantes mediante un modelo de regresión lineal múltiple. Los resultados permitirán al cliente apoyar decisiones estratégicas basadas en evidencia estadística, así como optimizar el gasto público en seguridad o diseñar nuevas propuestas para mejorar el sistema actual.

Antes de proceder, es importante no solamente saber la estructura interna de los datos o cómo se han almacenado, sino en un plano empírico, conocer su comportamiento en la vida real. Es decir, sería menester el **análisis univariante** de cada uno de los datos recopilados, para conocer su tendencia, dispersión y forma geométrica. El reconocimiento de patrones o ciertas tendencias pueden guiarnos para encontrar un diagnóstico acertado de las variables. De tal forma, garantizamos la correcta forma de trabajar con estos gracias a la identificación de **Outliers**, **Asimetría**, **Agrupación** y **Dispersión**.

Análisis Exploratorio de Datos

Análisis Univariante

```
resumen_integral <- datos_modelo %>%
  map_df(~ {
    es_num <- is.numeric(.x)
    data.frame(
      Tipo = class(.x)[1],
      Minimo = if(es_num) round(min(.x, na.rm = TRUE), 2) else NA,
      Q1 = if(es_num) round(quantile(.x, 0.25, na.rm = TRUE), 2) else NA,
      Mediana = if(es_num) round(median(.x, na.rm = TRUE), 2) else NA,
      Media = if(es_num) round(mean(.x, na.rm = TRUE), 2) else NA,
      Q3 = if(es_num) round(quantile(.x, 0.75, na.rm = TRUE), 2) else NA,
      Maximo = if(es_num) round(max(.x, na.rm = TRUE), 2) else NA,
      NAs = sum(is.na(.x))
    )
  }, .id = "Variable")

resumen_integral[is.na(resumen_integral)] <- "-"

kable(resumen_integral, format = "latex", longtable = TRUE, align = "c", row.names = FALSE,
      caption = "Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)") %>%
  kable_styling(latex_options = c("striped", "repeat_header", "hold_position"),
    full_width = FALSE, # <-- ¡Este es el cambio clave!
    font_size = 7) %>%
  row_spec(0, bold = TRUE, color = "white", background = "#2C3E50") %>%
  column_spec(1, bold = TRUE, width = "3cm") %>%
  column_spec(2, color = "#E67E22", bold = TRUE, width = "1.5cm") %>%
  column_spec(3, italic = TRUE, width = "4cm") %>% # Obliga al texto largo a saltar de línea
  column_spec(4:10, width = "1cm")
```

Table 2: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Minimo	Q1	Mediana	Media	Q3	Maximo	NAs
ViolentCrimesPerPop	numeric	0.02	0.17	0.32	0.39	0.54	1.00	0
medIncome	numeric	0.10	0.21	0.28	0.33	0.41	1.00	0
PctPopUnderPov	numeric	0.04	0.17	0.37	0.36	0.49	0.98	0
PctUnemployed	numeric	0.13	0.32	0.42	0.47	0.60	1.00	0
MalePctDivorce	numeric	0.16	0.39	0.50	0.51	0.62	0.88	0
PctKids2Par	numeric	0.00	0.25	0.45	0.46	0.63	0.91	0
PctTeen2Par	numeric	0.00	0.26	0.44	0.42	0.58	0.80	0
PctRecentImmig	numeric	0.01	0.09	0.19	0.28	0.40	1.00	0
MedRent	numeric	0.13	0.27	0.40	0.40	0.53	1.00	0
NumStreet	numeric	0.00	0.00	0.01	0.07	0.04	1.00	0
LemasSwFTPerPop	numeric	0.03	0.18	0.21	0.23	0.28	0.85	0
LemasPctOfficDrugUn	numeric	0.00	0.37	0.51	0.55	0.72	1.00	0
PolicOperBudg	numeric	0.00	0.01	0.02	0.07	0.05	1.00	0
PolicAveOTWorked	numeric	0.00	0.14	0.25	0.30	0.40	1.00	0
LemasTotReqPerPop	numeric	0.00	0.14	0.17	0.21	0.23	0.84	0
RentLowQ	numeric	0.09	0.23	0.33	0.35	0.47	0.79	0
FemalePctDiv	numeric	0.19	0.41	0.53	0.52	0.63	0.86	0
TotalPctDiv	numeric	0.18	0.42	0.54	0.54	0.65	0.90	0
county	integer	1.00	9.00	21.00	89.47	62.50	810.00	0

Conclusiones:

Un análisis del resumen estadístico revela varias conclusiones clave sobre la distribución de las variables:

- **Normalización de Datos:** Todas las variables presentan un mínimo de 0.00 y un máximo de 1.00. Esto confirma que el conjunto de datos ha sido prenormalizado, estableciendo una escala uniforme que evitará que las variables con números absolutos más grandes dominen de manera desproporcionada el modelo de regresión posterior. Esto es ideal para nuestro estudio.
- **Asimetría de la Variable Objetivo:** La variable dependiente, ViolentCrimesPerPop, muestra una media (**0.39**) que es mayor a su mediana (**0.32**). Esto indica una distribución asimétrica hacia la derecha. Es decir, la mayoría de las comunidades experimentan tasas más bajas de violencia, mientras que un subconjunto más pequeño sufre de condiciones de alta criminalidad que llevan el promedio hacia arriba.
- **Valores Atípicos Extremos:** Variables como NumStreet y PolicOperBudg demuestran una asimetría extrema hacia la derecha. Ambas poseen una mediana muy baja (0.01 y 0.02) pero alcanzan un máximo de 1.00. Este patrón sugiere que el número de personas sin hogar y los presupuestos operativos de la policía están altamente concentrados en unas pocas áreas específicas, en lugar de distribuirse uniformemente entre las comunidades.
- **Integridad de los Datos:** La columna NAs confirma que hay cero valores faltantes en este subconjunto refinado, lo que asegura una base sólida para las matrices de correlación y la regresión multivariante.