

Consultoría Estratégica: Esperanza de Vida

Data Solutions

Consultoría Propuesta

Uno de los aspectos más estudiados de la historia y que más interesa es la esperanza de vida, pues, al ser seres racionales, nuestro objetivo es **alargar la vida lo máximo posible**. Es por este motivo que *presentamos una base de datos dedicada a la esperanza de vida* y los factores que pueden influir en ella. Dicha base de datos es **Life Expectancy** (World Health Organization) y resulta idónea porque *recopila información de 193 países*, durante un periodo de 15 años (2000-2015).

La elección de esta base de datos se justifica plenamente por su relevancia analítica y su complejidad multivariante (22 variables). El proceso de modelización estadística de estos datos nos permitirán ser capaces de analizar como influyen las distintas variables a la esperanza de vida y como podemos **predecir casos futuros** basados en nuestro modelo. Además este dataset no está centrado en un solo ámbito, pues incluye variables explicativas de índole demográfica, económica y de salud.

Además, es de alto valor para el cliente porque traduce toda la complejidad numérica en decisiones estratégicas claras. Al identificar que factores tienen un impacto real en la longevidad, el cliente podrá **optimizar su inversión en recursos** y predecir el efecto de futuras políticas socioeconómicas.

Estudio de las variables

Visualización preliminar

Antes de profundizar en el código, debemos hacer un análisis preliminar de nuestras variables, esto nos permitirá seleccionar un subconjunto de mayor interés de las mismas.

```
datos <- read.csv("DATASET.csv")
options(scipen = 999)

library(knitr)
library(kableExtra)
```

```
## Warning: package 'kableExtra' was built under R version 4.5.3
```

```
library(dplyr)
```

```
##
```

```
## Adjuntando el paquete: 'dplyr'
```

```
## The following object is masked from 'package:kableExtra':
```

```
##
```

```
## group_rows
```

```
## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union

library(purrr)

resumen_integral <- datos %>%
  map_df(~ {
    es_num <- is.numeric(.x)
    data.frame(
      Tipo = class(.x)[1],
      Primeras_3_Obs = paste(head(.x, 3), collapse = " | "),
      Minimo = if(es_num) round(min(.x, na.rm = TRUE), 2) else NA,
      Q1 = if(es_num) round(quantile(.x, 0.25, na.rm = TRUE), 2) else NA,
      Mediana = if(es_num) round(median(.x, na.rm = TRUE), 2) else NA,
      Media = if(es_num) round(mean(.x, na.rm = TRUE), 2) else NA,
      Q3 = if(es_num) round(quantile(.x, 0.75, na.rm = TRUE), 2) else NA,
      Maximo = if(es_num) round(max(.x, na.rm = TRUE), 2) else NA,
      NAs = sum(is.na(.x))
    )
  }, .id = "Variable")

resumen_integral[is.na(resumen_integral)] <- "-"

kable(resumen_integral, format = "latex", booktabs = TRUE, align = "c", row.names = FALSE,
      caption = "Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)") %>%
  kable_styling(latex_options = c("scale_down", "hold_position")) %>%
  row_spec(0, bold = TRUE, color = "white", background = "#2C3E50") %>%
  column_spec(1, bold = TRUE) %>%
  column_spec(2, color = "#E67E22", bold = TRUE) %>%
  column_spec(3, italic = TRUE)
```

Información Detallada

En la tabla anterior, podemos ver un resumen de cada variable, así como unas primeras observaciones y el tipo de dato. A continuación presento la información detallada de cada una¹:

Variables Identificadoras

- **Country:** País de origen de los datos (Texto).
- **Year:** Año en el que se registraron las observaciones, desde el 2000 hasta el 2015 (Años).
- **Status:** Estado de desarrollo del país: “Developed” (Desarrollado) o “Developing” (En vías de desarrollo) (Binaria). Puede ser *bastante interesante para nuestro estudio*, ya que cómo bien es sabido, los países en desarrollo tienen menor acceso a servicios sanitarios en condiciones. No obstante, la variable añade una dificultad extra a la hora de ser implementada en el modelo, por eso debemos de cerciorarnos de hacerlo de forma correcta (por ej. **Función Indicatriz, Modelo de ANOVA**).

¹Kaggle: <https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who>

Table 1: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Primeras_3_Obs	Mínimo	Q1	Mediana	Media	Q3	Maximo	NAs
Country	character	Afghanistan / Afghanistan / Afghanistan	-	-	-	-	-	-	0
Year	integer	2015 / 2014 / 2013	2000	2004	2008	2007.52	2012	2015	0
Status	character	Developing / Developing / Developing	-	-	-	-	-	-	0
Life.expectancy	numeric	65 / 59.9 / 59.9	36.3	63.1	72.1	69.22	75.7	89	10
Adult.Mortality	integer	263 / 271 / 268	1	74	144	164.8	228	723	10
infant.deaths	integer	62 / 64 / 66	0	0	3	30.3	22	1800	0
Alcohol	numeric	0.01 / 0.01 / 0.01	0.01	0.88	3.76	4.6	7.7	17.87	194
percentage.expenditure	numeric	71.27962362 / 73.52358168 / 73.21924272	0	4.69	64.91	738.25	441.53	19479.91	0
Hepatitis.B	integer	65 / 62 / 64	1	77	92	80.94	97	99	553
Measles	integer	1154 / 492 / 430	0	0	17	2419.59	360.25	212183	0
BMI	numeric	19.1 / 18.6 / 18.1	1	19.3	43.5	38.32	56.2	87.3	34
under.five.deaths	integer	83 / 86 / 89	0	0	4	42.04	28	2500	0
Polio	integer	6 / 58 / 62	3	78	93	82.55	97	99	19
Total.expenditure	numeric	8.16 / 8.18 / 8.13	0.37	4.26	5.76	5.94	7.49	17.6	226
Diphtheria	integer	65 / 62 / 64	2	78	93	82.32	97	99	19
HIV.AIDS	numeric	0.1 / 0.1 / 0.1	0.1	0.1	0.1	1.74	0.8	50.6	0
GDP	numeric	584.25921 / 612.696514 / 631.744976	1.68	463.94	1766.95	7483.16	5910.81	119172.74	448
Population	numeric	33736494 / 327582 / 31731688	34	195793.25	1386542	12753375.12	7420359	1293859294	652
thinness..1.19.years	numeric	17.2 / 17.5 / 17.7	0.1	1.6	3.3	4.84	7.2	27.7	34
thinness.5.9.years	numeric	17.3 / 17.5 / 17.7	0.1	1.5	3.3	4.87	7.2	28.6	34
Income.composition.of.resources	numeric	0.479 / 0.476 / 0.47	0	0.49	0.68	0.63	0.78	0.95	167
Schooling	numeric	10.1 / 10 / 9.9	0	10.1	12.3	11.99	14.3	20.7	163

Variable Dependiente (Objetivo)

- **Life expectancy:** Esperanza de vida media al nacer (Años). Muy importante para lo que queremos estudiar.

Variables de Salud y Mortalidad

Todas estas variables pueden ser interesantes para determinar los grupos de riesgo entre la sociedad mundial, separando entre, por ejemplo, adultos y menores. Para contextualizar en mayor medida la naturaleza de los datos, hay que tener en cuenta que los valores que van de 0 a 100 son probabilidades (*cómo las variables correspondientes a 'thinness'*), mientras que los que van de 0 a 1000 (*variable 'Adult Mortality'*) son ratios que indican los desesos por cada mil habitantes de cierto subgrupo dividido por el rango de edad.

- **Adult Mortality:** Probabilidad de que ambos sexos mueran *entre los 15 y los 60 años* (Muertes por cada 1000 habitantes).
- **infant deaths:** Número de muertes de *bebés menores de 1 año* (Muertes por cada 1000 habitantes).
- **under-five deaths:** Número de muertes de niños *menores de 5 años* (Muertes por cada 1000 habitantes).
- **HIV/AIDS:** Número de muertes causadas por VIH/SIDA en niños de 0 a 4 años (Muertes por cada 1000 nacidos vivos).
- **BMI:** *Índice de Masa Corporal medio* de toda la población (Valor del índice).
- **thinness 1-19 years:** Prevalencia de *delgadez en niños y adolescentes* de 10 a 19 años (Porcentaje %).
- **thinness 5-9 years:** Prevalencia de *delgadez en niños* de 5 a 9 años (Porcentaje %).

Variables de Inmunización

- **Hepatitis B:** Cobertura de la vacuna contra la Hepatitis B en niños de 1 año (Porcentaje %).
- **Measles:** Número de casos de sarampión reportados (Casos por cada 1000 habitantes).

- **Polio:** Cobertura de la vacuna contra la Polio (Pol3) en niños de 1 año (Porcentaje %).
- **Diphtheria:** Cobertura de la vacuna contra la difteria, el tétanos y la tos ferina (DTP3) en niños de 1 año (Porcentaje %).

Variables Económicas y Sociales

- **GDP:** Producto Interior Bruto per cápita (Dólares estadounidenses USD).
- **percentage expenditure:** Gasto en salud como porcentaje del Producto Interior Bruto per cápita (Porcentaje %).
- **Total expenditure:** Gasto del gobierno en salud como porcentaje del gasto total del gobierno en todos los sectores (Porcentaje %).
- **Alcohol:** Consumo de alcohol per cápita en mayores de 15 años (Litros de alcohol puro).
- **Population:** Población total del país (Número de habitantes).
- **Income composition of resources:** Índice de Desarrollo Humano que evalúa la utilización productiva de los recursos o la composición de los ingresos (Índice de 0 a 1).
- **Schooling:** Número promedio de años de escolarización de la población (Años).

Identificación y Justificación de las Variables

Tras realizar una lectura exhaustiva, concluimos que las variables de interés para este estudio son:

Variable Dependiente (y):

- La **esperanza de vida (Life Expectancy)** es un indicador primordial para evaluar el bienestar de la población. Es por esto y su naturaleza continua que podemos aplicar técnicas de inferencia para cuantificar como ciertos factores estructurales alteran la longevidad.

Variables Explicativas (x_i):

- **Total expenditure (Gasto total):** Representa el presupuesto gubernamental en sanidad; Gasto en recursos hospitalarios e investigaciones que permiten prolongar la vida del individuo.
- **Alcohol:** Se considera por su toxicidad, debido a que en altas dosis puede reducir la longevidad.
- **Population (Población):** Si el tamaño de la población crece más rápido que la carga que la infraestructura sanitaria puede soportar, el sistema colapsa y los recursos disminuyen.
- **GPD (PIB):** Un mayor PIB refleja la capacidad de un país para financiar sistemas de salud robustos, infraestructuras de saneamiento e incluso acceso a agua potable. Todo esto reduce la mortalidad general elevando la esperanza de vida.
- **Schooling (Escolarización):** Determinantes sociales más importantes. La población educada tiende a adoptar hábitos preventivos.
- **Hepatitis B:** La inmunización a la enfermedad en el primer año de vida evita que el individuo desarrolle patologías hepáticas crónicas que se prolongen en toda su vida.

```
# Definimos Vector de las Variables de Interés
variables_estudio <- c("Life.expectancy", "Total.expenditure", "Alcohol",
                      "Population", "GDP", "Schooling", "Hepatitis.B", "Status")
datos_modelo <- datos[, variables_estudio]
```

- **Status (Estatus):** Clasifica el *nivel de desarrollo nacional*; influye en las **condiciones básicas de vida** y en el entorno de los ciudadanos. Como hemos mencionado anteriormente, la variable añade un factor extra de complejidad a nuestro modelo, por lo que **será implementada al final del estudio**. En este caso hemos optado por un **estudio de ANCOVA**. Tras tenerlo, *plantearemos cuál de los dos modelos es más óptimo*, si el simple o el ampliado.

Objetivo del Estudio

El objetivo principal es predecir la esperanza de vida nacional mediante un modelo de regresión lineal múltiple. Los resultados permitirán al cliente apoyar decisiones estratégicas basadas en evidencia estadística, así como optimizar el gasto público en sanidad o diseñar nuevas propuestas para mejorar los hábitos generales de la población.

Antes de proceder, es importante no solamente saber la estructura interna de los datos o cómo se han almacenado, sino en un plano empírico, conocer su comportamiento en la vida real. Es decir, sería menester el **análisis univariante** de cada uno de los datos recopilados, para conocer su tendencia, dispersión y forma geométrica. El reconocimiento de patrones o ciertas tendencias pueden guiarnos para encontrar un diagnóstico acertado de las variables. De tal forma, garantizamos la correcta forma de trabajar con estos gracias a la identificación de **Outliers**, **Asimetría**, **Agrupación** y **Dispersión**

Análisis Univariante

Para el análisis, estudiaríamos cada una de las variables de forma independiente, con las siguientes líneas de código:

```
resumen_integral <- datos_modelo %>%
  map_df(~ {
    es_num <- is.numeric(.x)
    data.frame(
      Tipo = class(.x)[1],
      Primeras_3_Obs = paste(head(.x, 3), collapse = " | "),
      Minimo = if(es_num) round(min(.x, na.rm = TRUE), 2) else NA,
      Q1 = if(es_num) round(quantile(.x, 0.25, na.rm = TRUE), 2) else NA,
      Mediana = if(es_num) round(median(.x, na.rm = TRUE), 2) else NA,
      Media = if(es_num) round(mean(.x, na.rm = TRUE), 2) else NA,
      Q3 = if(es_num) round(quantile(.x, 0.75, na.rm = TRUE), 2) else NA,
      Maximo = if(es_num) round(max(.x, na.rm = TRUE), 2) else NA,
      NAs = sum(is.na(.x))
    )
  }, .id = "Variable")

resumen_integral[is.na(resumen_integral)] <- "--"

kable(resumen_integral, format = "latex", booktabs = TRUE, align = "c", row.names = FALSE,
```

```
caption = "Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)" %>%
kable_styling(latex_options = c("scale_down", "hold_position")) %>%
row_spec(0, bold = TRUE, color = "white", background = "#2C3E50") %>%
column_spec(1, bold = TRUE) %>%
column_spec(2, color = "#E67E22", bold = TRUE) %>%
column_spec(3, italic = TRUE)
```

Table 2: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Primeras 3 Obs	Mínimo	Q1	Mediana	Media	Q3	Máximo	NAs
Life.expectancy	numeric	65 / 59.9 / 59.9	36.3	63.1	72.1	69.22	75.7	89	10
Total.expenditure	numeric	8.16 / 8.18 / 8.13	0.37	4.26	5.76	5.94	7.49	17.6	226
Alcohol	numeric	0.01 / 0.01 / 0.01	0.01	0.88	3.76	4.6	7.7	17.87	194
Population	numeric	33736494 / 327582 / 31731688	34	195793.25	1386542	12753375.12	7420359	1293859294	652
GDP	numeric	584.25921 / 612.696514 / 631.744976	1.68	463.94	1766.95	7483.16	5910.81	119172.74	448
Schooling	numeric	10.1 / 10 / 9.9	0	10.1	12.3	11.99	14.3	20.7	163
Hepatitis.B	integer	65 / 62 / 64	1	77	92	80.94	97	99	553
Status	character	Developing / Developing / Developing	-	-	-	-	-	-	0

Conclusiones:

- **Asimetría extrema (sesgo hacia la derecha):** Para la variable **Population** se registra una desigualdad increíble entre dos de las estimaciones de los datos, concretamente, entre la media y la varianza. En este caso para la media tenemos un valor de **12753375**, mientras que para la mediana de **1386542**, lo que es una diferencia mayor a diez millones, muchísimo. Lo mismo para la variable **GDP** con valores de **7483.16** y **1766.95** respectivos para la media y la mediana. En los dos casos encontramos que la media es muchísimo mayor a la mediana, siendo un claro indicio de que gran parte de la cantidad de los datos se reparten en valores más pequeños para el PIB y la población. En conclusión, para estas dos variables, encontramos una asimetría hacia la derecha.
- **Desigualdad radical en los rangos:** La esperanza de vida mínima registrada en un país es alarmante, de **36.3 años**, lo que vienen siendo el mínimo de los datos. En cambio, algo muy similar pasa para la cobertura de la **Hepatitis B**, en la que tenemos *escenarios muy polarizados*: la mayoría de los datos son esperanzadores, gran parte de los países llegan a vacunar a casi todos sus niños (mediana de **93%**), pero el cambio, el mínimo registrado es de apenas un **1%**. Son datos alarmante, ya que el retraso de la vacuna de la hepatitis B no solamente *pone en riesgo la vida del recién nacido*, sino que intrínsecamente *empeora la calidad de vida del individuo* con el contagio de enfermedades crónicas que se prolongan en la vida, *deteriorando su calidad de vida* a lo largo de los años (En consecuencia, teniendo una esperanza de vida mucho menor).

A continuación presentamos la forma en la que se distribuyen los datos de nuestro Dataset:

```
## Warning: package 'ggplot2' was built under R version 4.5.2
```

```
## Warning: package 'patchwork' was built under R version 4.5.2
```

```
## Warning: Removed 2246 rows containing non-finite outside the scale range
## (`stat_bin()`).
```

Histogramas de Variables Numéricas



