

Consultoría estratégica: Crímenes Violentos

Data Solutions

Consultoría Propuesta

Uno de los aspectos que más preocupan a los ciudadanos, es su seguridad. Queremos ser capaces de poder ir por donde queramos, cuando queramos, sin que haya riesgo de que alguien salga perjudicado. Es por este motivo que presentamos una base de datos dedicada a los crímenes violentos, y el estudio de sus posibles causas. Dicha base de datos es “Communities and Crime”¹.

La elección de esta base de datos se justifica plenamente debido a que recopila datos reales del censo estadounidense de 1990, el informe de crímenes reportados del FBI de 1995 y del estudio de estadísticas administrativas y del uso de la ley de 1990. Esta base de datos fue creada por Michael Redmon.

Además, es de alto valor para el cliente porque traduce toda la complejidad numérica en decisiones estratégicas claras. Al identificar que factores tienen un impacto real en los crímenes violentos, el cliente podrá optimizar su inversión en recursos y predecir el efecto de futuras políticas socioeconómicas.

Estudio de las variables

Visualización preliminar

Antes de profundizar en el código, debemos hacer un análisis preliminar de nuestras variables, esto nos permitirá seleccionar un subconjunto de mayor interés de las mismas.

Debido a la gran dimensionalidad del conjunto de datos (128 variables), el análisis exploratorio integral se ha exportado a un documento externo para facilitar la lectura².

¹Enlace de Referencia: <https://archive.ics.uci.edu/dataset/183/communities+and+crime>

²Haz clic aquí para visualizar el resumen completo de las variables: https://drive.google.com/file/d/1WrsFtFY3zNsvuFvzZ2tWkxx_d-aRj-G2/view?usp=sharing

Table 1: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Primeras 3 Obs	NAs
state	integer	8 / 53 / 24	0
county	integer	NA / NA / NA	1174
community	integer	NA / NA / NA	1177
communityname	character	Lakewoodcity / Tukwilacity / Aberdeentown	0
fold	integer	1 / 1 / 1	0
population	numeric	0.19 / 0 / 0	0
householdsize	numeric	0.33 / 0.16 / 0.42	0
racepctblack	numeric	0.02 / 0.12 / 0.49	0
racePctWhite	numeric	0.9 / 0.74 / 0.56	0
racePctAsian	numeric	0.12 / 0.45 / 0.17	0

Información Variables y Justificación de Elección

En la tabla anterior, podemos ver un resumen de cada variable, así como unas primeras observaciones y el tipo de dato.

Debido al alto número de variables, hemos seleccionado un subconjunto de 18 variables, que creemos serán de mayor interés para el estudio.

A continuación, presento la información detallada de cada una:

Variable Dependiente (Objetivo)

- **ViolentCrimesPerPop:** Número total de crímenes violentos por cada cien mil habitantes. Esta es nuestra variable de mayor interés.

Variables Explicativas

Variables Identificadoras

- **county:** Código numérico por condado (Esta no es predictiva pero nos sirve para un estudio más denso o detectar motivos ocultos).

Variables del Uso de la Ley

- **LemasPctOfficDrugUn:** Porcentaje de oficiales asignados a la unidad de drogas. Nos interesa mucho, pues las drogas causan relaciones violentas en los individuos.
- **PolicOperBudg:** Presupuesto operativo de la policía. Muy interesante, pues es veremos si más policías significan menos crímenes.
- **PolicAveOTWorked:** Media de tiempo extra (o fuera de horario de contrato) trabajado.
- **LemasTotReqPerPop:** Total de veces que se ha solicitado a la policía por cada cien mil personas.
- **LemasSwFTPerPop:** Número de oficiales de la policía por cada cien mil habitantes.

Variables de Situación Familiar

- **MalePctDivorce:** Porcentaje de individuos de género masculino que están divorciados. A veces los divorcios se realizan debido a situaciones violentas por parte del hombre.
- **FemalePctDiv:** Porcentaje de individuos de género femenino que están divorciadas.
- **TotalPctDiv:** Porcentaje de la población que está divorciada. Muchas de las situaciones violentas resultan en divorcio, es muy importante.
- **PctKids2Par:** Porcentaje de niños que viven con sus dos padres. Esta variable puede presentar una correlación negativa con la variable dependiente, ya que a mejor situación familiar, menor riesgo hay de tensiones en la familia que desemboquen en violencia doméstica..
- **PctTeen2Par:** Porcentaje de niños de 12-17 años de edad que viven conjuntamente con sus padres (en la misma casa).

Variables Económicas

En general todas las siguientes creemos que influyen, pues normalmente, cuanto peor es la situación económica, más probabilidad hay de infelicidad y violencia, aunque lo analizaremos más adelante.

- **medIncome:** Mediana de las ganancias por hogar.
- **PctPopUnderPov:** Porcentaje de personas por debajo de el nivel de pobreza.
- **PctUnemployed:** Porcentaje de personas de 16 años o más, en trabajos forzados o desempleados.
- **RentLowQ:** Cuartil 25 del coste de la renta.
- **MedRent:** Mediana de la renta bruta.

Variables Sociales

- **PctRecentImmig:** Porcentaje de la población que ha inmigrado en los últimos 3 años. En algunas ocasiones, puede influir el descontento o choque de culturas al principio.
- **NumStreet:** Número de personas sin hogar contadas en las calles. Muy importante para nuestro estudio.

Todas las variables presentadas son numéricas, el dataset no contiene variables categóricas de interés con las que construir un modelo anova o ancova tras nuestra regresión múltiple lineal.

Objetivo del estudio

El objetivo principal es predecir el número de crímenes violentos por cada cien mil habitantes mediante un modelo de regresión lineal múltiple. Los resultados permitirán al cliente apoyar decisiones estratégicas basadas en evidencia estadística, así como optimizar el gasto público en seguridad o diseñar nuevas propuestas para mejorar el sistema actual.

Antes de proceder, es importante no solamente saber la estructura interna de los datos o cómo se han almacenado, sino en un plano empírico, conocer su comportamiento en la vida real. Es decir, sería menester el **análisis univariante** de cada uno de los datos recopilados, para conocer su tendencia, dispersión y forma geométrica. El reconocimiento de patrones o ciertas tendencias pueden guiarnos para encontrar un diagnóstico acertado de las variables. De tal forma, garantizamos la correcta forma de trabajar con estos gracias a la identificación de **Outliers**, **Asimetría**, **Agrupación** y **Dispersión**.

Análisis Exploratorio de Datos

Análisis Univariante

Table 2: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Mínimo	Q1	Mediana	Media	Q3	Maximo	NAs
ViolentCrimesPerPop	numeric	0.02	0.17	0.32	0.39	0.54	1.00	0
medIncome	numeric	0.10	0.21	0.28	0.33	0.41	1.00	0
PctPopUnderPov	numeric	0.04	0.17	0.37	0.36	0.49	0.98	0
PctUnemployed	numeric	0.13	0.32	0.42	0.47	0.60	1.00	0
MalePctDivorce	numeric	0.16	0.39	0.50	0.51	0.62	0.88	0
PctKids2Par	numeric	0.00	0.25	0.45	0.46	0.63	0.91	0

Table 2: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas) (*continued*)

Variable	Tipo	Mínimo	Q1	Mediana	Media	Q3	Maximo	NAs
PctTeen2Par	numeric	0.00	0.26	0.44	0.42	0.58	0.80	0
PctRecentImmig	numeric	0.01	0.09	0.19	0.28	0.40	1.00	0
MedRent	numeric	0.13	0.27	0.40	0.40	0.53	1.00	0
NumStreet	numeric	0.00	0.00	0.01	0.07	0.04	1.00	0
LemasSwFTPerPop	numeric	0.03	0.18	0.21	0.23	0.28	0.85	0
LemasPctOfficDrugUn	numeric	0.00	0.37	0.51	0.55	0.72	1.00	0
PolicOperBudg	numeric	0.00	0.01	0.02	0.07	0.05	1.00	0
PolicAveOTWorked	numeric	0.00	0.14	0.25	0.30	0.40	1.00	0
LemasTotReqPerPop	numeric	0.00	0.14	0.17	0.21	0.23	0.84	0
RentLowQ	numeric	0.09	0.23	0.33	0.35	0.47	0.79	0
FemalePctDiv	numeric	0.19	0.41	0.53	0.52	0.63	0.86	0
TotalPctDiv	numeric	0.18	0.42	0.54	0.54	0.65	0.90	0
county	integer	1.00	9.00	21.00	89.47	62.50	810.00	0

Conclusiones:

Un análisis del resumen estadístico revela varias conclusiones clave sobre la distribución de las variables:

- **Normalización de Datos:** Todas las variables presentan un mínimo de 0.00 y un máximo de 1.00. Esto confirma que el conjunto de datos ha sido prenormalizado, estableciendo una escala uniforme que evitará que las variables con números absolutos más grandes dominen de manera desproporcionada el modelo de regresión posterior. Esto es ideal para nuestro estudio.
- **Asimetría de la Variable Objetivo:** La variable dependiente, ViolentCrimesPerPop, muestra una media (0.39) que es mayor a su mediana (0.32). Esto indica una distribución asimétrica hacia la derecha. Es decir, la mayoría de las comunidades experimentan tasas más bajas de violencia, mientras que un subconjunto más pequeño sufre de condiciones de alta criminalidad que llevan el promedio hacia arriba.
- **Valores Atípicos Extremos:** Variables como NumStreet y PolicOperBudg demuestran una asimetría extrema hacia la derecha. Ambas poseen una mediana muy baja (0.01 y 0.02) pero alcanzan un máximo de 1.00. Este patrón sugiere que el número de personas sin hogar y los presupuestos operativos de la policía están altamente concentrados en unas pocas áreas específicas, en lugar de distribuirse uniformemente entre las comunidades.
- **Integridad de los Datos:** La columna NAs confirma que hay cero valores faltantes en este subconjunto refinado, lo que asegura una base sólida para las matrices de correlación y la regresión multivariante.

Análisis bivalente

Por otro lado, conviene realizar un **análisis bivalente** entre la variable objetivo y el resto de variables, para ver cuáles tienen mayor relación lineal con nuestra variable respuesta y cuáles nos aportan información extra relevante.

Para ellos, primero analizaremos la matriz de correlación simple y posteriormente la matriz de correlaciones parciales y las visualizaremos.

Correlaciones simples

El primer paso es evaluar la relación lineal directa entre todas las variables. Esto nos ayuda a identificar los predictores más fuertes para ViolentCrimesPerPop y nos da una primera pista visual sobre posibles variables explicativas que estén muy correlacionadas entre sí.

Correlaciones Simples con ViolentCrimesPerPop

Variable

Correlacion

PctPopUnderPov

0.742

PctUnemployed

0.733

FemalePctDiv

0.691

TotalPctDiv

0.691

MalePctDivorce

0.661

NumStreet

0.504

LemasSwFTPerPop

0.416

PolicOperBudg

0.402

LemasTotReqPerPop

0.375

PolicAveOTWorked

0.221

PctRecentImmig

0.078

county

0.013

LemasPctOfficDrugUn

-0.029

MedRent

-0.393

RentLowQ

-0.472

medIncome


-0.576

PctTeen2Par

-0.830

PctKids2Par

-0.846



Conclusiones de correlaciones simples:

En la tabla de correlación simple con nuestra variable objetivo ViolentCrimesPerPop, observamos que la inmigración reciente (PctRecentImmig), el condado (county) y el porcentaje de oficiales (LemasPctOfficDrugUn) asignados a la unidad de drogas casi no tienen correlación alguna con los crímenes violentos.

Por otro lado vemos que el porcentaje de personas que viven en pobreza (PctPopUnderPov) y de desempleados (PctUnemployed), así como de divorcios en general (FemalePctDiv, TotalPctDiv, MalePctDivorce) tienen una correlación positiva elevada, que indica que una mala situación personal o familiar puede resultar en violencia. Además, el porcentaje de niños y adolescentes que viven con sus dos padres juntos (PctKids2Par y PctTeen2Par respectivamente) tienen una correlación negativa muy elevada, lo que indica que actúan como un fuerte factor de protección frente a la criminalidad.

Primer vistazo de la multicolinealidad:

Al observar el gráfico de correlaciones simples completo y centrándonos en los tonos azul y rojo oscuros, detectamos alta colinealidad entre ciertas variables. Por ejemplo las tres métricas de divorcio están altamente correlacionadas entre sí, al igual que los indicadores de estructura familiar y las variables económicas (como la relación inversa entre la pobreza y los ingresos medios). Esto nos advierte, de que varios de estos predictores nos proporcionan información redundante, por lo tanto, es indispensable aplicar técnicas de diagnóstico para evitar que la redundancia desestabilice nuestro modelo.

Table 3: Correlaciones Parciales con ViolentCrimesPerPop

Variable	Correlacion_Parcial
PctUnemployed	0.247
NumStreet	0.210
TotalPctDiv	0.121
PolicAveOTWorked	0.069
LemasTotReqPerPop	0.057
MedRent	0.028
medIncome	0.027
county	0.020
LemasSwFTPerPop	0.018
RentLowQ	0.001
PolicOperBudg	-0.036
PctPopUnderPov	-0.064
LemasPctOfficDrugUn	-0.086
PctRecentImmig	-0.087
FemalePctDiv	-0.112
MalePctDivorce	-0.116
PctTeen2Par	-0.126
PctKids2Par	-0.138

Correlaciones parciales

Conclusiones de Correlaciones Parciales:

Tras la realización de las correlaciones parciales, observamos una caída drástica en el efecto que tenían todas las variables respecto a la variable dependiente. Este resultado confirma un alto grado de multicolinealidad, al asumir que varios conjuntos de variables están relacionadas de forma muy fuerte. En definitiva, muchas de estas métricas socioeconómicas comparten información redundante y explican el mismo comportamiento subyacente. Por ejemplo, para las métricas que describen el porcentaje de divorciados hay una clara relación, en el sentido de que el porcentaje total de los divorciados (**TotalPctDvr**) es básicamente la suma de los subgrupos de divorciados de hombres y mujeres (**MalePctDrv**, **FemalePctDivorce** respectivamente), por lo que no añaden nada de información nueva, una se pueda explicar con las dos restantes. Esto se ve reflejado en la pérdida de la correlación de estas dos últimas métricas, que incluso pasan a tener un efecto negativo.

A pesar de esta reducción, el análisis muestra los verdaderos motores de la criminalidad en las comunidades. El desempleo (**PctUnemployed**) y las personas sin hogar (**NumStreet**) destacan como los principales desencadenantes de la violencia registrada (encontramos una correlación positiva), mientras que lo contrario pasa con las variables que describen los hogares estables (**PctKids2Par**, **PctTeen2Par**). A mayor porcentaje de hijos que viven sin padres divorciados, menores parecen ser los registros de violencia en aquel condado. Por otra parte, identificamos que la pobreza (**PctPopUnderPov**) pierde su impacto estadístico al ser aislada, demostrando que es la mezcla de factores como las condiciones de precariedad laboral y desentendimientos familiares (cómo pueden ser los divorcios) junto con la mencionada, los que realmente aumentan la exposición al estrés, y por ende los casos de violencia.

Finalmente, vemos que esto no solamente pasa con la pobreza, sino factores como el porcentaje de inmigración reciente pierden su importancia.

Selección de Variables Explicativas

Tras los datos observados de las relaciones simples y parciales, razonaremos que factores socioeconómicos tienen más relevancia para determinar los casos de violencia registrado en un condado determinado. Para nuestro estudio, recopilaremos los **predictores que presenten una relación lineal** lo más apreciable posible.

Las variables que demuestran un coeficiente de correlación de Pearson más bajo que el resto, están representadas por facotes como la inmigración (`PctRecentImmig`), el código de territorio (`county`) y el porcentaje de agentes adheridos a la unidad de drogas (`LemasPctOfficDrugUn`). En estos casos, podemos detectar un Coeficiente de Correlación Parcial bastante pequeño, en todos los casos tenemos que $|\rho| < 0.1$.

Como hemos mencionado antes, los resultados del test de Correlación Parcial frente al Simple son mucho menores, como por ejemplo, para las variables `TotalPctDiv` y `FemalePctDiv`, las cuales han bajado de **0.661** a valores muy inferiores, incluso en el caso de `FemalePctDiv`, pasando a tener una correlación negativa. Este es un claro ejemplo de **Multicolinealidad**, muchos de estos factores no aportan información nueva, ya que describen cosas muy parecidas. O sea, a pesar de que sus Correlaciones con la variable independiente fueran altas, debemos determinar la dependencia que tienen las variables explicativas entre ellas, para optar por un modelo lo más optimizado posible eliminando cualquier redundancia.

Siguiendo por el ejemplo de los divorcios, tras el último estudio, nos quedamos con un $\rho = 0.112$. Para solucionar esto, nos quedaríamos con una de las variables tres variables que explican lo mismo, y cómo la tasa total del divorcio en nuestro estudio consta del valor más alto, nos quedaríamos con la columna **TotalPctDiv**.

Pasemos a las variables que representan el **estado socioeconómico** del condado, en concreto las variables **PctPopUnderPov**, **medIncome**, **PctUnemployed**, conservaremos únicamente **PctUnemployed**, ya que demostró ser el verdadero impulsor directo de la criminalidad al aislar su efecto $\rho = 0.247$, siendo el mayor de toda la simulación. Siguiendo con el resto de efectos, los que corresponden al *Uso de la Ley* son grandes candidatos determinísticos para los casos de violencia por población, ya que como es de esperar, a más efecto policiales, más seguridad por las calles y viceversa. En este aspecto optamos por el *tamaño del cuerpo policial* (**LemasSwFTPerPop**), ya que como con la variable anterior, mantiene una alta colinealidad con las variables del mismo tipo. De este modo, excluiríamos de nuestro modelo a al presupuesto operativo (**PolicOperBudg**) y el nivel de demanda de los ciudadanos (**LemasTotReqPerPop**).

Finalmente y para acabar con la selección del motor del modelo, nos queda uno de los factores que parece reducir nuestra variable dependiente, teniendo un efecto negativo sobre esta. Parece ser que los hijos de padres que viven en una misma unidad doméstica (representan) determina la reducción de casos de violencia doméstica.

De este modo, hemos conseguido reducir la dimensionalidad para evitar inestabilidades en las varianzas de los coeficientes en el futuro, proponiendo entonces, un modelo de regresión múltiple parsimonioso compuesto por seis variables explicativas definitivas: `PctKids2Par`, `PctUnemployed`, `TotalPctDiv`, `NumStreet`, `LemasSwFTPerPop` y `LemasTotReqPerPop`.

```
variables_finales <- c(
  "ViolentCrimesPerPop",
  "PctKids2Par",
  "PctUnemployed",
  "TotalPctDiv",
  "NumStreet",
  "LemasSwFTPerPop"
)

datos_modelo_final <- datos_modelo[, variables_finales]
```


Table 4: Resumen de Coeficientes del Modelo Lineal Múltiple

	Estimación	Error Estándar	Valor t	P-valor
(Intercept)	0.4219	0.1569	2.6897	8.171e-03
PctKids2Par	-0.6112	0.1238	-4.9367	2.592e-06
PctUnemployed	0.2715	0.0947	2.8679	4.883e-03
TotalPctDiv	0.1277	0.1347	0.9478	3.451e-01
NumStreet	0.2769	0.0789	3.5091	6.338e-04
LemasSwFTPerPop	0.1256	0.1517	0.8278	4.094e-01

Ajuste del modelo e Inferencia

En base a la selección de variables previa, proponemos un modelo de Regresión Lineal Múltiple para predecir la tasa de crímenes violentos. El modelo teórico poblacional se especifica mediante la siguiente ecuación:

$$ViolentCrimesPerPop = \beta_0 + \beta_1 PctKids2Par + \beta_2 PctUnemployed + \beta_3 TotalPctDiv + \beta_4 NumStreet + \beta_5 LemasSwFTPerPop + \epsilon$$

Donde:

β_0 representa el intercepto.

$\beta_1, \dots, \beta_5$ son los coeficientes parciales de regresión que miden el cambio en la variable dependiente por cada unidad de cambio en la variable independiente correspondiente.

ϵ es el término de error aleatorio, asumiendo $\epsilon \sim N(0, \sigma^2)$.

```
# Ajustamos el modelo lineal múltiple con las variables definitivas
modelo_final <- lm(ViolentCrimesPerPop ~ PctKids2Par + PctUnemployed + TotalPctDiv + NumStreet + LemasSwFTPerPop)

# Extraemos los principales resultados (coeficientes y significatividad)
sfit <- summary(modelo_final)
tabla_coef <- as.data.frame(sfit$coefficients)

colnames(tabla_coef) <- c("Estimación", "Error Estándar", "Valor t", "P-valor")

tabla_coef$Estimación <- round(tabla_coef$Estimación, 4)
tabla_coef$Error Estándar <- round(tabla_coef$Error Estándar, 4)
tabla_coef$Valor t <- round(tabla_coef$Valor t, 4)

tabla_coef$P-valor <- formatC(tabla_coef$P-valor, format = "e", digits = 3)

kable(tabla_coef, format = "latex", align = "c",
      caption = "Resumen de Coeficientes del Modelo Lineal Múltiple") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive"),
                full_width = FALSE) %>%
  row_spec(0, bold = TRUE, color = "white", background = "#2C3E50") %>%
  column_spec(1, bold = TRUE) %>%
  column_spec(5, color = ifelse(sfit$coefficients[,4] < 0.05, "#27AE60", "black"), bold = ifelse(sfit$coefficients[,4] < 0.05, TRUE, FALSE))
```

Interpretación de los resultados:

Intercepto (β_0): El valor predicho del intercepto es 0.4219, siendo estadísticamente significativo (p-valor = 8.171e-03). Esto indica que, si todas las variables del modelo fuesen cero, la tasa base esperada de crímenes violentos sería de 0.4219.

Por otro lado, al analizar la magnitud de los coeficientes, los factores que presentan un impacto estadísticamente significativo sobre la variable dependiente son PctKids2Par con un coeficiente de -0.6112 (p-valor = 2.592e-06), su impacto es el más fuerte y altamente significativo de todo el modelo. Por cada unidad que aumenta la proporción de niños en hogares biparentales, la tasa de crímenes violentos disminuye drásticamente en 0.6112 unidades, asumiendo que el resto de variables se mantienen constantes. Por otra parte NumStreet tiene un impacto positivo y significativo de 0.2769 (p-valor = 6.338e-04). A mayor presencia de personas sin hogar en las calles, mayor es la tasa de crímenes violentos registrada. Y por último PctUnemployed también muestra un efecto positivo y significativo estimado en 0.2715 (p-valor = 4.883e-03), confirmando que el desempleo actúa como un claro impulsor directo de la criminalidad.

Efectos No Significativos: De forma muy clara, el modelo detecta que la tasa de divorcios (TotalPctDiv, p-valor = 3.451e-01) y el número de efectivos policiales (LemasSwFTPerPop, p-valor = 4.094e-01) no son estadísticamente significativos para este modelo. Esto nos sugiere que, una vez controlados el desempleo, el sinhogarismo y la estructura familiar, ni los divorcios a nivel general ni la cantidad de policías en las calles aportan una influencia demostrable estadísticamente sobre la variación de los crímenes violentos.

Intervalos de Confianza

```
# Calculamos los intervalos de confianza al 95%
intervalos <- confint(modelo_final, level = 0.95)
tabla_intervalos <- as.data.frame(intervalos)

kable(tabla_intervalos, format = "latex", align = "c",
      caption = "Intervalos de Confianza al 95% para los Coeficientes") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"), full_width = FALSE) %>%
  row_spec(0, bold = TRUE, color = "white", background = "#2C3E50")
```

\begin{table} \caption{Intervalos de Confianza al 95% para los Coeficientes}

	2.5 %	97.5 %
(Intercept)	0.1113330	0.7324984
PctKids2Par	-0.8563789	-0.3660941
PctUnemployed	0.0840706	0.4589808
TotalPctDiv	-0.1390401	0.3943935
NumStreet	0.1206591	0.4331059
LemasSwFTPerPop	-0.1748001	0.4259750

\end{table}

Los intervalos de confianza confirman matemáticamente nuestras observaciones previas los predictores PctKids2Par, NumStreet y PctUnemployed no cruzan el cero, demostrando significancia estadística. En cambio, los intervalos de los divorcios (TotalPctDiv) y la presencia policial (LemasSwFTPerPop) sí incluyen el cero, confirmando de forma definitiva la falta de evidencia de que realmente influyan en el crimen en este modelo.