



UNIVERSIDAD MIGUEL HERNÁNDEZ DE ELCHE

Consultoría estratégica: Crímenes Violentos Data Solutions

Grado en Ciencia de Datos e Inteligencia Artificial

Autores:

Nora Infantes Llinares y Hugo
Rodríguez Carretero

Profesor:

Juan Aparicio, Ricardo Gonzalez y
Alejandro Astor

May 10, 2026

Table 1: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Primeras_3_Obs	NAs
state	integer	8 / 53 / 24	0
county	integer	NA / NA / NA	1174
community	integer	NA / NA / NA	1177
communityname	character	Lakewoodcity / Tukwilacity / Aberdeentown	0
fold	integer	1 / 1 / 1	0
population	numeric	0.19 / 0 / 0	0
householdsize	numeric	0.33 / 0.16 / 0.42	0
racepctblack	numeric	0.02 / 0.12 / 0.49	0
racePctWhite	numeric	0.9 / 0.74 / 0.56	0
racePctAsian	numeric	0.12 / 0.45 / 0.17	0

Consultoría Propuesta

Uno de los aspectos que más preocupan a los ciudadanos, es su seguridad. Queremos ser capaces de poder ir por donde queramos, cuando queramos, sin que haya riesgo de que alguien salga perjudicado. Es por este motivo que presentamos una base de datos dedicada a los crímenes violentos, y el estudio de sus posibles causas. Dicha base de datos es “Communities and Crime”¹.

La elección de esta base de datos se justifica plenamente debido a que recopila datos reales del censo estadounidense de 1990, el informe de crímenes reportados del FBI de 1995 y del estudio de estadísticas administrativas y del uso de la ley de 1990. Esta base de datos fue creada por Michael Redmon.

Además, es de alto valor para el cliente porque traduce toda la complejidad numérica en decisiones estratégicas claras. Al identificar que factores tienen un impacto real en los crímenes violentos, el cliente podrá optimizar su inversión en recursos y predecir el efecto de futuras políticas socioeconómicas.

Estudio de las variables

Visualización preliminar

Antes de profundizar en el código, debemos hacer un análisis preliminar de nuestras variables, esto nos permitirá seleccionar un subconjunto de mayor interés de las mismas.

Debido a la gran dimensionalidad del conjunto de datos (128 variables), el análisis exploratorio integral se ha exportado a un documento externo para facilitar la lectura².

Información Variables y Justificación de Elección

En la tabla anterior, podemos ver un resumen de cada variable, así como unas primeras observaciones y el tipo de dato.

Debido al alto número de variables, hemos seleccionado un subconjunto de 18 variables, que creemos serán de mayor interés para el estudio.

A continuación, presento la información detallada de cada una:

¹Enlace de Referencia: <https://archive.ics.uci.edu/dataset/183/communities+and+crime>

²Haz clic aquí para visualizar el resumen completo de las variables: https://drive.google.com/file/d/1WrsFtFY3zNsvuFvzZ2tWkxx_d-aRj-G2/view?usp=sharing

Variable Dependiente (Objetivo)

- **ViolentCrimesPerPop:** Número total de crímenes violentos por cada cien mil habitantes. Esta es nuestra variable de mayor interés.

Variables Explicativas

Variables Identificadoras

- **county:** Código numérico por condado (Esta no es predictiva pero nos sirve para un estudio más denso o detectar motivos ocultos).

Variables del Uso de la Ley

- **LemasPctOfficDrugUn:** Porcentaje de oficiales asignados a la unidad de drogas. Nos interesa mucho, pues las drogas causan relaciones violentas en los individuos.
- **PolicOperBudg:** Presupuesto operativo de la policía. Muy interesante, pues es veremos si más policías significan menos crímenes.
- **PolicAveOTWorked:** Media de tiempo extra (o fuera de horario de contrato) trabajado.
- **LemasTotReqPerPop:** Total de veces que se ha solicitado a la policía por cada cien mil personas.
- **LemasSwFTPerPop:** Número de oficiales de la policia por cada cien mil habitantes.

Variables de Situación Familiar

- **MalePctDivorce:** Porcentaje de individuos de género masculino que están divorciados. A veces los divorcios se realizan debido a situaciones violentas por parte del hombre.
- **FemalePctDiv:** Porcentaje de individuos de género femenino que están divorciadas.
- **TotalPctDiv:** Porcentaje de la población que está divorciada. Muchas de las situaciones violentas resultan en divorcio, es muy importante.
- **PctKids2Par:** Porcentaje de niños que viven con sus dos padres. Esta variable puede presentar una correlación negativa con la variable dependiente, ya que a mejor situación familiar, menor riesgo hay de tensiones en la familia que desemboquen en violencia doméstica..
- **PctTeen2Par:** Porcentaje de niños de 12-17 años de edad que viven conjuntamente con sus padres (en la misma casa).

Variables Económicas

En general todas las siguientes creemos que influyen, pues normalmente, cuanto peor es la situación económica, más probabilidad hay de infelicidad y violencia, aunque lo analizaremos más adelante.

- **medIncome:** Mediana de las ganancias por hogar.
- **PctPopUnderPov:** Porcentaje de personas por debajo de el nivel de pobreza.
- **PctUnemployed:** Porcentaje de personas de 16 años o más, en trabajos forzados o desempleados.
- **RentLowQ:** Cuartil 25 del coste de la renta.
- **MedRent:** Mediana de la renta bruta.

Variables Sociales

- **PctRecentImmig:** Porcentaje de la población que ha inmigrado en los últimos 3 años. En algunas ocasiones, puede influir el descontento o choque de culturas al principio.
- **NumStreet:** Número de personas sin hogar contadas en las calles. Muy importante para nuestro estudio.

Todas las variables presentadas son numéricas, el dataset no contiene variables categóricas de interés con las que construir un modelo anova o ancova tras nuestra regresión múltiple lineal.

Objetivo del estudio

El objetivo principal es predecir el número de crímenes violentos por cada cien mil habitantes mediante un modelo de regresión lineal múltiple. Los resultados permitirán al cliente apoyar decisiones estratégicas basadas en evidencia estadística, así como optimizar el gasto público en seguridad o diseñar nuevas propuestas para mejorar el sistema actual.

Antes de proceder, es importante no solamente saber la estructura interna de los datos o cómo se han almacenado, sino en un plano empírico, conocer su comportamiento en la vida real. Es decir, sería menester el **análisis univariante** de cada uno de los datos recopilados, para conocer su tendencia, dispersión y forma geométrica. El reconocimiento de patrones o ciertas tendencias pueden guiarnos para encontrar un diagnóstico acertado de las variables. De tal forma, garantizamos la correcta forma de trabajar con estos gracias a la identificación de **Outliers, Asimetría, Agrupación y Dispersión**.

Análisis Exploratorio de Datos

Análisis Univariante

Table 2: Análisis Exploratorio Integral: Todas las Variables (Numéricas y Categóricas)

Variable	Tipo	Mínimo	Q1	Mediana	Media	Q3	Maximo	NAs
ViolentCrimesPerPop	numeric	0.02	0.17	0.32	0.39	0.54	1.00	0
medIncome	numeric	0.10	0.21	0.28	0.33	0.41	1.00	0
PctPopUnderPov	numeric	0.04	0.17	0.37	0.36	0.49	0.98	0
PctUnemployed	numeric	0.13	0.32	0.42	0.47	0.60	1.00	0
MalePctDivorce	numeric	0.16	0.39	0.50	0.51	0.62	0.88	0
PctKids2Par	numeric	0.00	0.25	0.45	0.46	0.63	0.91	0
PctTeen2Par	numeric	0.00	0.26	0.44	0.42	0.58	0.80	0
PctRecentImmig	numeric	0.01	0.09	0.19	0.28	0.40	1.00	0
MedRent	numeric	0.13	0.27	0.40	0.40	0.53	1.00	0
NumStreet	numeric	0.00	0.00	0.01	0.07	0.04	1.00	0
LemasSwFTPerPop	numeric	0.03	0.18	0.21	0.23	0.28	0.85	0
LemasPctOfficDrugUn	numeric	0.00	0.37	0.51	0.55	0.72	1.00	0
PolicOperBudg	numeric	0.00	0.01	0.02	0.07	0.05	1.00	0
PolicAveOTWorked	numeric	0.00	0.14	0.25	0.30	0.40	1.00	0
LemasTotReqPerPop	numeric	0.00	0.14	0.17	0.21	0.23	0.84	0
RentLowQ	numeric	0.09	0.23	0.33	0.35	0.47	0.79	0
FemalePctDiv	numeric	0.19	0.41	0.53	0.52	0.63	0.86	0
TotalPctDiv	numeric	0.18	0.42	0.54	0.54	0.65	0.90	0
county	integer	1.00	9.00	21.00	89.47	62.50	810.00	0

Conclusiones:

Un análisis del resumen estadístico revela varias conclusiones clave sobre la distribución de las variables:

- **Normalización de Datos:** Todas las variables presentan un mínimo de 0.00 y un máximo de 1.00. Esto confirma que el conjunto de datos ha sido prenormalizado, estableciendo una escala uniforme que evitará que las variables con números absolutos más grandes dominen de manera desproporcionada el modelo de regresión posterior. Esto es ideal para nuestro estudio.
- **Asimetría de la Variable Objetivo:** La variable dependiente, `ViolentCrimesPerPop`, muestra una media (0.39) que es mayor a su mediana (0.32). Esto indica una distribución asimétrica hacia la derecha. Es decir, la mayoría de las comunidades experimentan tasas más bajas de violencia, mientras que un subconjunto más pequeño sufre de condiciones de alta criminalidad que llevan el promedio hacia arriba.
- **Valores Atípicos Extremos:** Variables como `NumStreet` y `PolicOperBudg` demuestran una asimetría extrema hacia la derecha. Ambas poseen una mediana muy baja (0.01 y 0.02) pero alcanzan un máximo de 1.00. Este patrón sugiere que el número de personas sin hogar y los presupuestos operativos de la policía están altamente concentrados en unas pocas áreas específicas, en lugar de distribuirse uniformemente entre las comunidades.
- **Integridad de los Datos:** La columna `NAs` confirma que hay cero valores faltantes en este subconjunto refinado, lo que asegura una base sólida para las matrices de correlación y la regresión multivariante.

Análisis bivalente

Por otro lado, conviene realizar un **análisis bivalente** entre la variable objetivo y el resto de variables, para ver cuáles tienen mayor relación lineal con nuestra variable respuesta y cuáles nos aportan información extra relevante.


Para ellos, primero analizaremos la matriz de correlación simple y posteriormente la matriz de correlaciones parciales y las visualizaremos.

Correlaciones simples

El primer paso es evaluar la relación lineal directa entre todas las variables. Esto nos ayuda a identificar los predictores más fuertes para `ViolentCrimesPerPop` y nos da una primera pista visual sobre posibles variables explicativas que estén muy correlacionadas entre sí.

Table 3: Correlaciones Simples con ViolentCrimesPerPop

Variable	Correlacion
PctPopUnderPov	0.742
PctUnemployed	0.733
FemalePctDiv	0.691
TotalPctDiv	0.691
MalePctDivorce	0.661
NumStreet	0.504
LemasSwFTPerPop	0.416
PolicOperBudg	0.402
LemasTotReqPerPop	0.375
PolicAveOTWorked	0.221
PctRecentImmig	0.078
county	0.013
LemasPctOfficDrugUn	-0.029
MedRent	-0.393
RentLowQ	-0.472
medIncome	-0.576
PctTeen2Par	-0.830
PctKids2Par	-0.846



Conclusiones de correlaciones simples:

En la tabla de correlación simple con nuestra variable objetivo ViolentCrimesPerPop, observamos que la inmi-

Table 4: Correlaciones Parciales con ViolentCrimesPerPop

Variable	Correlacion_Parcial
PctUnemployed	0.247
NumStreet	0.210
TotalPctDiv	0.121
PolicAveOTWorked	0.069
LemasTotReqPerPop	0.057
MedRent	0.028
medIncome	0.027
county	0.020
LemasSwFTPPerPop	0.018
RentLowQ	0.001
PolicOperBudg	-0.036
PctPopUnderPov	-0.064
LemasPctOfficDrugUn	-0.086
PctRecentImmig	-0.087
FemalePctDiv	-0.112
MalePctDivorce	-0.116
PctTeen2Par	-0.126
PctKids2Par	-0.138

gración reciente (PctRecentImmig), el condado (county) y el porcentaje de oficiales (LemasPctOfficDrugUn) asignados a la unidad de drogas casi no tienen correlación alguna con los crímenes violentos.

Por otro lado vemos que el porcentaje de personas que viven en pobreza (PctPopUnderPov) y de desempleados (PctUnemployed), así como de divorcios en general (FemalePctDiv, TotalPctDiv, MalePctDivorce) tienen una correlación positiva elevada, que indica que una mala situación personal o familiar puede resultar en violencia. Además, el porcentaje de niños y adolescentes que viven con sus dos padres juntos (PctKids2Par y PctTeen2Par respectivamente) tienen una correlación negativa muy elevada, lo que indica que actúan como un fuerte factor de protección frente a la criminalidad.

Primer vistazo de la multicolinealidad:

Al observar el gráfico de correlaciones simples completo y centrándonos en los tonos azul y rojo oscuros, detectamos alta colinealidad entre ciertas variables. Por ejemplo las tres métricas de divorcio están altamente correlacionadas entre sí, al igual que los indicadores de estructura familiar y las variables económicas (como la relación inversa entre la pobreza y los ingresos medios).

Conclusion Clave: Multicolinealidad

Esto nos advierte, de que varios de estos predictores nos proporcionan información redundante, por lo tanto, es indispensable aplicar técnicas de diagnóstico para evitar que la redundancia desestabilice nuestro modelo.

Correlaciones parciales

Conclusiones de Correlaciones Parciales:

Tras la realización de las correlaciones parciales, observamos una caída drástica en el efecto que tenían todas las variables respecto a la variable dependiente. Este resultado confirma un alto grado de multicolinealidad, al asumir que varios conjuntos de variables están relacionadas de forma muy fuerte. En definitiva, muchas de estas métricas socioeconómicas comparten información redundante y explican el mismo comportamiento subyacente. Por ejemplo, para las métricas que describen el porcentaje de divorciados hay una clara relación,

en el sentido de que el porcentaje total de los divorciados (**TotalPctDvr**) es básicamente la suma de los subgrupos de divorciados de hombres y mujeres (**MalePctDrv**, **FemalePctDivorce** respectivamente), por lo que no añaden nueva información relevante, una se pueda explicar con las dos restantes. Esto se ve reflejado en la pérdida de la correlación de estas dos últimas métricas, que incluso paran a tener un efecto negativo.

A pesar de esta reducción, el análisis muestra los verdaderos motores de la criminalidad en las comunidades. El desempleo (**PctUnemployed**) y las personas sin hogar (**NumStreet**) destacan cómo los principales desencadenantes de la violencia registrada (encontramos una correlación positiva), mientras que lo contrario pasa con las variables que describen los hogares estables (**PctKids2Par**, **PctTeen2Par**). A mayor porcentaje de hijos que viven sin padres divorciados, menores parecen ser los registros de violencia en aquel condado. Por otra parte, identificamos que la pobreza (**PctPopUnderPov**) pierde su impacto estadístico al ser aislada, demostrando que es la mezcla de factores cómo las condiciones de precariedad laboral y desentendimientos familiares (cómo pueden ser los divorcios) junto con la mencionada, los que realmente aumente la exposición al estrés, y por ende los casos de violencia.

Finalmente, vemos que esto no solamente pasa con la pobreza, sino factores cómo el porcentaje de inmigración reciente pierden su importancia.

Selección de Variables Explicativas

Tras los datos observados de las relaciones simples y parciales, razonaremos que factores socioeconómicos tienen más relevancia para determinar los casos de violencia registrado en un condado determinado. Para nuestro estudio, recopilaremos los **predictores que presenten una relación lineal** lo más apreciable posible.

Las variables que demuestran un coeficiente de correlación de Pearson más bajo que el resto, están representadas por factores cómo la inmigración (**PctRecentImmig**), el código de territorio (**county**) y el porcentaje de agentes adheridos a la unidad de drogas (**LemasPctOfficDrugUn**). En estos casos, podemos detectar un Coeficiente de Correlación Parcial bastante pequeño, en todos los casos tenemos que $|\rho| < 0.1$.

Como hemos mencionado antes, los resultados del test de Correlación Parcial frente al Simple son mucho menores, cómo por ejemplo, para las variables **TotalPctDiv** y **FemalePctDiv**, las cuales han bajado de **0.661** a valores muy inferiores, incluso en el caso de **FemalePctDiv**, pasando a tener una correlación negativa. Este es un claro ejemplo de **Multicolinealidad**, muchos de estos factores no aportan información nueva, ya que describen cosas muy parecidas. O sea, a pesar de que sus Correlaciones con la variable independiente fueran altas, debemos de determinar la dependencia que tienen las variables explicativas entre ellas, para optar por un modelo lo más optimizado posible eliminando cualquier redundancia.

Siguiendo por el ejemplo de los divorcios, tras el último estudio, nos quedamos con un $\rho = 0.112$. Para solucionar esto, nos quedaríamos con una de las variables tres variables que explican la misma, y cómo la tasa total del divorcio en nuestro estudio consta del valor más alto, nos quedaríamos con la columna **TotalPctDiv**.

Pasemos a las variables que representan el **estado socioeconómico** del condado, en concreto las variables **PctPopUnderPov**, **medIncome**, **PctUnemployed**, conservaremos únicamente **PctUnemployed**, ya que demostró ser el verdadero impulsor directo de la criminalidad al aislar su efecto $\rho = 0.247$, siendo el mayor de toda la simulación. Siguiendo con el resto de efectos, los que corresponden al *Uso de la Ley* son grandes candidatos determinísticos para los casos de violencia por población, ya que cómo es de esperar, a más efecto policiales, más seguridad por las calles y viceversa. En este aspecto optamos por el *tamaño del cuerpo policial* (**LemasSwFTPerPop**), ya que cómo con la variable anterior, mantiene una alta colinealidad con las variables del mismo tipo. De este modo, excluiríamos de nuestro modelo a al presupuesto operativo (**PolicOperBudg**) y el nivel de demanda de los ciudadanos (**LemasTotReqPerPop**).

Finalmente y para acabar con la selección del motor del modelo, nos queda uno de los factores que parece reducir nuestra variable dependiente, teniendo un efecto negativo sobre esta. Parece ser que los hijos de padres que viven en una misma unidad doméstica determina la reducción de casos de violencia doméstica.

Table 5: Resumen de Coeficientes del Modelo Lineal Múltiple

	Estimación	Error Estándar	Valor t	P-valor
(Intercept)	0.4219	0.1569	2.6897	8.171e-03
PctKids2Par	-0.6112	0.1238	-4.9367	2.592e-06
PctUnemployed	0.2715	0.0947	2.8679	4.883e-03
TotalPctDiv	0.1277	0.1347	0.9478	3.451e-01
NumStreet	0.2769	0.0789	3.5091	6.338e-04
LemasSwFTPerPop	0.1256	0.1517	0.8278	4.094e-01

Nos quedaríamos con la variable más fuerte que representa el conjunto total de los datos, **PctKids2Par**, ya que su hermana **PctTeens2Par** es solamente un subconjunto de la misma, y la redundancia en este caso está más que clara.

Variables de nuestro modelo

Hemos conseguido reducir la dimensionalidad para evitar inestabilidades en las varianzas de los coeficientes en el futuro, proponiendo entonces, un modelo de regresión múltiple parsimonioso compuesto por seis variables explicativas definitivas: PctKids2Par, PctUnemployed, TotalPctDiv, NumStreet, LemasSwFTPerPop y LemasTotReqPerPop.

Ajuste del modelo e Inferencia

En base a la selección de variables previa, proponemos un modelo de Regresión Lineal Múltiple para predecir la tasa de crímenes violentos. El modelo teórico poblacional se especifica mediante la siguiente ecuación:

$$ViolentCrimesPerPop = \beta_0 + \beta_1 PctKids2Par + \beta_2 PctUnemployed + \beta_3 TotalPctDiv + \beta_4 NumStreet + \beta_5 LemasSwFTPerPop$$

Donde:

β_0 representa el intercepto.

$\beta_1, \dots, \beta_5$ son los coeficientes parciales de regresión que miden el cambio en la variable dependiente por cada unidad de cambio en la variable independiente correspondiente.

ϵ es el término de error aleatorio, asumiendo $\epsilon \sim N(0, \sigma^2)$.

Interpretación de los resultados:

- **Intercepto** (β_0): El valor predicho del intercepto es **0.4219**, siendo *estadísticamente significativo* (**p-valor = 8.171e-03**). Esto indica que, *si todas las variables del modelo fuesen cero*, la tasa base esperada de crímenes violentos sería de 0.4219.

Tras analizar la magnitud de los coeficientes, los **factores que presentan un impacto estadísticamente significativo** sobre la variable dependiente son **PctKids2Par** con un coeficiente de -0.6112 (p-valor = **2.592e-06**), su impacto es el más fuerte y altamente significativo de todo el modelo. Por cada unidad que *aumenta la proporción de niños en hogares biparentales*, la tasa de *crímenes violentos disminuye* drásticamente en 0.6112 unidades, asumiendo que el resto de variables se mantienen constantes. Por otra parte **NumStreet** tiene un impacto positivo y significativo de 0.2769 (p-valor = **6.338e-04**). A *mayor presencia de personas sin hogar en las calles*, *mayor es la tasa de crímenes violentos* registrada. Y por último **PctUnemployed** también muestra un efecto positivo y significativo estimado en 0.2715 (p-valor = **4.883e-03**), confirmando que el desempleo actúa como un claro impulsor directo de la criminalidad.

Efectos No Significativos: De forma muy clara, el modelo detecta que la tasa de divorcios (**TotalPctDiv**, $p\text{-valor} = 3.451e-01$) y el número de efectivos policiales (**LemasSwFTPerPop**, $p\text{-valor} = 4.094e-01$) *no son estadísticamente significativos* para este modelo. Esto nos sugiere que, una vez controlados el desempleo, el sinhogarismo y la estructura familiar, ni los divorcios a nivel general ni la cantidad de policías en las calles aportan una influencia demostrable estadísticamente sobre la variación de los crímenes violentos.

Intervalos de Confianza

Table 6: Intervalos de Confianza al 95% para los Coeficientes

	Inferior (2.5)	Superior (97.5)
(Intercept)	0.1113330	0.7324984
PctKids2Par	-0.8563789	-0.3660941
PctUnemployed	0.0840706	0.4589808
TotalPctDiv	-0.1390401	0.3943935
NumStreet	0.1206591	0.4331059
LemasSwFTPerPop	-0.1748001	0.4259750

Los intervalos de confianza confirman matemáticamente nuestras observaciones previas los predictores PctKids2Par, NumStreet y PctUnemployed **no cruzan el cero**, demostrando *significancia estadística*. En cambio, los intervalos de los **divorcios** (TotalPctDiv) y la **presencia policial** (LemasSwFTPerPop) **sí incluyen el cero**, confirmando de forma definitiva la *falta de evidencia de que realmente influyan* en el crimen en este modelo.

Recomendaciones Estratégicas:

Asumiendo que el resto de variables se mantienen constantes (*ceteris paribus*), las decisiones estratégicas para reducir la criminalidad deben centrarse en los predictores significativos. En primer lugar, conviene aumentar la proporción de familias biparentales (PctKids2Par), ya que su coeficiente negativo y de alta precisión (-0.6112) tiene un fuerte efecto preventivo, lo que justifica invertir en políticas de ayuda y conciliación familiar.

Por el contrario, se deben reducir el sinhogarismo (NumStreet, 0.2769) y el desempleo (PctUnemployed, 0.2715), invirtiendo en la inserción laboral y la red de vivienda social, pues son los claros impulsores del crimen. Finalmente, dado que el volumen de efectivos policiales carece de significatividad estadística, recomendamos aumentar la eficacia del despliegue de seguridad actual en lugar de simplemente aumentar el número de agentes, priorizando la inversión en las variables socioeconómicas mencionadas anteriormente.

La magnitud de impacto preventivo de familias biparentales es mayor que el sinhogarismo y el desempleo, pero no por ello hay que dejar de invertir las dos últimas, pues siguen teniendo magnitudes importantes.

Evaluación de la Bondad de Ajuste

Para garantizar la fiabilidad de nuestras predicciones, evaluamos la bondad del ajuste mediante tres criterios métricos fundamentales.

Contraste de Significación Global (ANOVA)

Este contraste nos servirá para evaluar si la *variabilidad explicada por el modelo ajustado es suficientemente grande* comparada con la que queda sin explicar (la de los residuos). Para ello, *plantearemos si el conjunto de variables explicativas aporta información conjunta significativa*, enfrentando la siguiente hipótesis nula frente a la alternativa:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-1} = 0$$

$$H_1 : \text{algún } \beta_i \neq 0$$

El **estadístico de contraste** que usaremos de referencia, que bajo H_0 se distribuye como una F de Fisher con $p - 1$ y $n - p$ grados de libertad, es:

$$F = \frac{SSR/(p-1)}{SSE/(n-p)} = \frac{MSR}{MSE} \sim F_{(p-1, n-p)}$$

TABLA DE ANOVA GLOBAL

##	gl	SS	MS	F	p-valor
## Regresión	5	7.0656	1.4131	76.5312	0.000e+00
## Error	120	2.2157	0.0185		
## Total	125	9.2813			

Observando los resultados obtenidos de nuestro modelo, el *estadístico F obtenido es 76.5312* con un **p-valor de 0** aproximadamente. Dado que el p-valor es estrictamente inferior a 0.05, **rechazamos la hipótesis nula H_0** .

Conclusión: ANOVA

El modelo es globalmente significativo y que las variables seleccionadas predicen conjuntamente la criminalidad de forma válida. Al menos una de las variables predictoras aporta información relevante para explicar el comportamiento de la variable dependiente.

Coeficiente de Determinación (R^2)

El coeficiente de determinación R^2 se define como la parte proporcional de la variabilidad de los datos que es explicada por el modelo ajustado:

$$R^2 = \frac{SSR}{S_{yy}} = 1 - \frac{SSE}{S_{yy}}$$

Puesto que siempre es posible conseguir un R^2 artificialmente grande añadiendo más términos , utilizamos su versión ajustada, R_a^2 , que penaliza la inclusión de variables innecesarias al tener en cuenta los grados de libertad.

$$R_a^2 = 1 - \left(\frac{n-1}{n-p} \right) [1 - R^2]$$

Nuestro modelo presenta un R^2 múltiple de **0.7613** y un R_a^2 ajustado de **0.751321**. Esto indica que nuestras variables explicativas logran capturar y explicar aproximadamente el 75.13% de la variabilidad total de los crímenes violentos. Este es un **ajuste robusto y satisfactorio**, especialmente tratándose de modelización de comportamiento socioeconómico.

Table 7: Coeficientes de Determinación

Metrica	Valor
R2 Múltiple	0.7613
R2 Ajustado	0.7513

Table 8: Métricas de Error Residual

Metrica	Valor
Desviación Típica de los Residuos (s)	0.1359
Coefficiente de Variación (CV %)	35.1700

Desviación Típica de los Residuos (s) y Coeficiente de Variación (CV)

La suma de cuadrados residual, SSE , da una medida de la desviación entre las observaciones y las estimaciones del modelo. Dividiendo por sus grados de libertad ($n - p$), obtenemos la varianza residual. Su raíz cuadrada es el error residual estimado s ($\hat{\sigma}$):

$$s = \sqrt{MSE} = \sqrt{\frac{SSE}{n - p}}$$

Para valorar si este error de predicción es grande o pequeño de forma relativa, calculamos su Coeficiente de Variación (CV), dividiendo s entre la media observada de la respuesta $\bar{y}$:

$$CV = \frac{s}{\bar{y}} \cdot 100$$

Con un Coeficiente de Variación del 35.17% ($s = 0.1359$), **el error relativo supera el umbral del 30%**. Esto nos indica que, aunque el modelo es excelente para analizar los impulsores del crimen a nivel estratégico, las predicciones numéricas exactas para comunidades individuales tendrán un **margen de error considerable** que debe tenerse en cuenta.

Diagnóstico del Modelo (Análisis de Residuos)

Para garantizar que nuestras estimaciones e inferencias sean **matemáticamente válidas**, debemos comprobar que los residuos de nuestro modelo cumplen las *hipótesis fundamentales del modelo de regresión lineal*. Si alguna falla, las predicciones o los niveles de significatividad podrían estar sesgados.

Normalidad de los Residuos

Asumimos que los errores siguen una distribución normal centrada en cero:


$$H_0 : \epsilon_i \sim N(0, \sigma^2)$$

Para realizar este diagnóstico, en lugar de utilizar los residuos comunes, evaluamos los residuos externamente **estudentizados** (rt_i). Esta transformación es necesaria porque aísla la influencia de los datos originales (de la matriz de diseño) y estabiliza la varianza de los errores, evaluándose matemáticamente como:

$$rt_i = \frac{e_i}{\sqrt{s_{(i)}^2(1 - h_{ii})}}$$


Comenzamos el diagnóstico con una inspección visual a través del **Gráfico Q-Q** (QQ-Plot). Este gráfico contrasta los residuos de nuestro modelo contra los valores teóricos esperados si la distribución fuera perfectamente normal.

Gráfico Q-Q de Normalidad



Como complemento visual al QQ-Plot, que es muy *sensible a los valores extremos*, utilizamos el histograma para comprobar de un vistazo la simetría y la forma de la distribución.

Histograma de Residuos



Por último, para evitar valoraciones subjetivas de los gráficos, corroboramos las evidencias mediante pruebas estadísticas. Calcularemos el **test de Shapiro-Wilk** y el de **Kolmogorov-Smirnov**. A nivel de consultoría, basaremos nuestra conclusión definitiva en el test de *Shapiro-Wilk*, ya que es una prueba específica diseñada exclusivamente para **evaluar la normalidad**. El test de *Kolmogorov-Smirnov* se presenta como apoyo, pero al ser un **contraste de bondad** de ajuste de propósito general, tiene menor potencia analítica para este caso.

1.3 Contrastes Formales de Normalidad

```
shapiro.test(r)
```

```
##
## Shapiro-Wilk normality test
##
## data:  r
## W = 0.99018, p-value = 0.5141
```

```
ks.test(r, "pnorm", mean = mean(r), sd = sd(r))
```

```
##
## Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  r
## D = 0.052455, p-value = 0.8787
## alternative hypothesis: two-sided
```


A nivel visual, el gráfico Q-Q nos generaba confusión en los valores atípicos, aunque lo demás siguiera una normal pero el *histograma nos confirma y muestra una clara tendencia asimilable a la campana de Gauss*.

Analíticamente, la prueba principal de Shapiro-Wilk nos devuelve un **p-valor de 0.5141**, mientras que el test de soporte de Kolmogorov-Smirnov resulta en un **p-valor de 0.8787**. Dado que ambos *p-valores son muy superiores a 0.05*, aceptamos la hipótesis nula, concluyendo que el supuesto de normalidad se cumple de forma satisfactoria, validando la solidez de nuestras inferencias estadísticas anteriores.

Homocedasticidad

Para que las estimaciones de los intervalos de confianza y los p-valores de nuestro modelo sean fiables, debemos cumplir la hipótesis de homocedasticidad. Es decir, la **varianza de los errores** debe mantenerse **constante** para cualquier valor predicho; en términos de negocio, el modelo no debe equivocarse más en las comunidades con alta criminalidad que en las de criminalidad baja.

Iniciaremos el diagnóstico con un **análisis gráfico**, representando los residuos frente a los *valores ajustados predichos* ($\hat{y}_i$). El objetivo de esta visualización es ver una *nube de puntos aleatoria y sin tendencias*, con forma de banda horizontal en torno al cero. Si la varianza no fuera constante (heterocedasticidad), observaríamos patrones claros, como una forma de “embudo”.



Para corroborar de forma rigurosa la inspección visual, utilizamos el **test de Breusch-Pagan**. Elegimos este test porque está diseñado para modelos de regresión y evalúa específicamente si la magnitud de los residuos puede ser explicada matemáticamente por nuestras variables predictoras.

$$H_0 : Var(\epsilon_i) = \sigma^2$$

$$H_1 : Var(\epsilon_i) = f(x_i) \quad (\text{Heterocedasticidad})$$

```
# 2.2 Contraste Formal de Homocedasticidad (Breusch-Pagan)
library(lmtest)

bp_test <- bptest(modelo_final)

cat("Test de Breusch-Pagan: BP =", bp_test$statistic, ", p-valor =", bp_test$p.value, "\n")
```

```
## Test de Breusch-Pagan: BP = 8.303741 , p-valor = 0.1402713
```

Aunque el análisis gráfico inicial nos generaba ciertas dudas debido a las desviaciones ligeramente pronunciadas de la línea de tendencia, el test estadístico **descarta nuestro problema**. El test de Breusch-Pagan tiene un estadístico $BP = 8.3037$ con un **p-valor de 0.1403**. Como el p-valor es muy superior a 0.05, no podemos rechazar la hipótesis nula. Q

Conclusión: Hay Homocedasticidad

Queda corroborado estadísticamente que el supuesto de homocedasticidad se cumple de forma satisfactoria y estadísticamente significativa. Esto nos asegura que el margen de error de nuestras predicciones sea estable a lo largo de los distintos niveles de criminalidad estimados.

Supuesto de Incorrelación

A continuación, vamos a comprobar si los errores (los residuos) de nuestro modelo son realmente aleatorios. El supuesto de **Independencia** exige que el error que comete el modelo al predecir el crimen de una comunidad no tenga absolutamente nada que ver con la consecutiva predicción. En caso de haber un orden subyacente en el muestreo (por ejemplo, si los datos estuviesen *ordenados geográficamente o por cercanía* al haberlos tomado). Para esto distinguimos **tres métodos** para asegurar este supuesto:

• 1.- Correlación serial

En un modelo lineal clásico ideal, la matriz de varianzas y covarianzas de los errores dicta que $Cov(\epsilon_i, \epsilon_j) = 0$ para cualquier $i \neq j$.

La **correlación serial** rompe esta regla, ocurre cuando el error actual ϵ_i está matemáticamente ligado al error separado por s posiciones (ϵ_{i-s}). La ecuación que define el comportamiento de los residuos es la siguiente:

$$\epsilon_i = \rho\epsilon_{i-1} + u_i$$

- ϵ_i : Es el residuo actual que comete tu modelo (la diferencia entre el crimen real y el que tú has predicho).
- ρ (rho): Es el parámetro crítico, el coeficiente de autocorrelación (varía de -1 a 1).
- ϵ_{i-1} : Es el residuo de la observación inmediatamente anterior en tu base de datos.
- u_i : Es el “ruido blanco”. Representa el error intrínseco, puramente aleatorio e impredecible.

Nota sobre la Correlación

En caso de haber correlación, las estimaciones de nuestro modelo empeoran cómo si fueran fichas de dominó. Si nuestro modelo sobreestima la tasa de violencia en una observación, también lo hará en la siguiente, teniendo una correlación serial positiva.

• 2.- Gráficos Lag


Una de las herramientas para determinar de forma empírica este supuesto es de forma visual mediante un gráfico lag. En este, se ordenan los residuos en función del orden secuencial que aparecen las observaciones en la base de datos.

De esta forma distinguimos la correlación si los puntos de nuestra gráfica siguen un especie de tendencia, en vez de estar distribuidos de forma completamente aleatoria.

Limitaciones

Como en estadística el "ojo humano" no es suficiente para publicar un trabajo, usamos este contraste matemático para dar un veredicto final, el Test de Durbin-Watson (La prueba Final), el cual desarrollaremos a continuación.

En el siguiente gráfico, dibujamos en el eje X el residuo de la observación anterior (ϵ_{i-1}), y en el eje Y el residuo de la observación actual (ϵ_i). Así cuadra perfectamente con el título de tu gráfico.



Claramente, no distinguir ver una tendencia clara en la que se apoyen los punto. De hecho, los residuos forman una nube de puntos, distribuidos de forma aleatoria. Esto juega a favor de nuestro modelo, ya que no hay indicios de que al tomar los datos en cierto orden/muestreo, se hayan podido ‘contagiar’ unos a otros.

• 3.- Test de Durbin-Watson

Planteamos el test de Durbin-Watson con la finalidad de determinar de forma clara y final la correlación de los datos. En consecuencia, tenemos el siguiente análisis:

- **Hipótesis Nula (H_0):** La verdadera autocorrelación de los residuos es cero (es decir, independencia).
- **El Estadístico (d):** El test calcula la suma de las diferencias al cuadrado entre residuos consecutivos dividida por la varianza total de los residuos. La magia de esta fórmula es que siempre arroja un valor acotado entre **0 y 4**. Se define de la siguiente forma:
 - $d \approx 2$: No hay correlación serial (Aceptamos H_0).
 - d cercano a 0: Alarma. Hay correlación serial positiva evidente.
 - d cercano a 4: Alarma. Hay correlación serial negativa.

$$d = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}$$

Para valores de n suficientemente grandes podemos desarrollar el binomio, llegando a una aproximación fundamental que conecta el estadístico con el coeficiente de autocorrelación ($\hat{\rho}$):

$$d \approx 2(1 - \hat{\rho})$$

* Si $\hat{\rho} \approx 0$ (Hay Independencia), entonces $d \approx 2(1 - 0) = 2$. * Si $\hat{\rho} > 0$ (Correlación positiva), la resta se hace pequeña y $d < 2$ (tiende a 0). * Si $\hat{\rho} < 0$ (Correlación negativa), el paréntesis suma y $d > 2$ (tiende a 4).

```
# Ejecutamos el test formal sobre el modelo
dwtest(modelo_final)
```

```
##
## Durbin-Watson test
##
## data: modelo_final
## DW = 1.8378, p-value = 0.1807
## alternative hypothesis: true autocorrelation is greater than 0
```

Tras el desarrollo del estimador en nuestro caso tenemos que su p-valor asociado es igual a **0.18** > 0.05. En nuestro caso, no tenemos evidencia suficiente para rechazar la hipótesis nula, por lo que entendemos que **los residuos no están correlacionados de ninguna forma entre ellos**.

Conclusión: Ausencia de Incorrelación entre Residuos

Tras ver la ausencia de una traza distinguible en el gráfico Lag y confirmar nuestros supuestos con el test de Durbin-Watson, podemos afirmar el Supuesto de Incorrelación. Garantizamos la precisión del modelo y de los contrastes estadísticos, evitando conclusiones falsas.


Existencia de Valores Sobreinfluyentes

Para continuar es *crucial identificar si existe un subconjunto reducido de datos que altere de manera desproporcionada el ajuste* y las estimaciones finales. En nuestro contexto, esto significaría que **una única comunidad con dinámicas criminales extremas** estaría “tirando” de la recta de regresión como un imán, **sesgando todas nuestras recomendaciones**.

Por consiguiente, para diagnosticar este problema, la métrica principal es la **Distancia de Cook** (D_i). Este estadístico mide el impacto global de una observación calculando exactamente cuánto cambiarían los coeficientes del modelo si excluyéramos ese punto específico del análisis. Matemáticamente se define como:

$$D_i = \frac{(\hat{\beta}_{(i)} - \hat{\beta})' X' X (\hat{\beta}_{(i)} - \hat{\beta})}{ps^2}$$

Donde $\hat{\beta}_{(i)}$ representa el vector de coeficientes estimados sin la observación i . Si obtenemos un valor $D_i > 1$ indica que esa observación es altamente influyente para la estabilidad de nuestro modelo.



Im(ViolentCrimesPerPop ~ PctKids2Par + PctUnemployed + TotalPctDiv + NumStr ..

El análisis visual realizado es excelente para nuestro modelo, sin embargo, a nivel técnico **necesitamos un análisis analítico riguroso** para corroborar con la visualización. Para ello, calculamos la matriz completa de medidas de influencia globales. Con esta matriz podremos evaluar múltiples métricas avanzadas como **DFBETAS** para el *impacto en predicciones*, **DFBETAS** para el *impacto en cada coeficiente* y **COVRATIO** para la *precisión general* y además sabremos si algún registro desestabiliza el modelo.

```
# 4.2 Análisis Analítico Exhaustivo
# Calculamos la matriz completa de medidas de influencia
medidas_influencia <- influence.measures(modelo_final)
```

```
# Extraemos un resumen de las observaciones marcadas como potencialmente influyentes
summary(medidas_influencia)
```

```
## Potentially influential observations of
## lm(formula = ViolentCrimesPerPop ~ PctKids2Par + PctUnemployed + TotalPctDiv + NumStreet + Len
##
##      dfb.1_ dfb.PK2P dfb.PctU dfb.TtPD dfb.NmSt dfb.LSFT dffit   cov.r   cook.d
## 2   -0.24   0.27   -0.26    0.52    0.51   -0.09   0.78_*   0.92    0.10
## 3    0.11  -0.02   -0.14    0.06    0.02   -0.31   0.49   0.66_*   0.04
## 15  -0.02   0.02    0.04   -0.03    0.12    0.06   0.17   1.17_*   0.00
## 31   0.00   0.00   -0.02    0.01    0.06    0.01   0.06   1.34_*   0.00
## 32   0.19  -0.24    0.04   -0.14   -0.16   -0.12   0.46   0.72_*   0.03
## 53   0.30  -0.35    0.02   -0.11  -1.74_*  -0.44  -1.91_*   0.91    0.56
## 77  -0.34   0.16   -0.23    0.25    0.08   1.10_*  1.26_*   1.48_*   0.26
## 87  -0.01   0.00    0.00    0.00    0.00    0.01  -0.01   1.16_*   0.00
## 102  0.16  -0.18   -0.21    0.01   -0.03   -0.13   0.33   0.84_*   0.02
## 114  0.07  -0.07   -0.02   -0.08   -0.02   -0.02   0.08   1.25_*   0.00
## 118 -0.11   0.08   -0.04    0.09   -0.33    0.25  -0.45   1.66_*   0.03
##      hat
## 2     0.11
## 3     0.02
## 15    0.11
## 31    0.22_*
## 32    0.03
## 53    0.27_*
## 77    0.38_*
## 87    0.09
## 102   0.02
## 114   0.16_*
## 118   0.38_*
```

Al evaluar analíticamente la **matriz de medidas de influencia globales**, la salida muestra las observaciones más influyentes. Tenemos registros como el **53** y el **77** que presentan *características atípicas* (evidenciadas por un alto apalancamiento en la columna hat) que llegan a alterar ligeramente predicciones puntuales (dffit) o incluso coeficientes individuales (dfb). Por otro lado, la mayoría de las observaciones listadas aparecen marcadas casi exclusivamente por *afectar levemente a la amplitud de los intervalos de confianza* (cov.r), pero no **suponen un sesgo real para las estimaciones**.

Sin embargo, el indicador definitivo para evaluar el peligro estructural sobre el modelo es la distancia de Cook (cook.d). Al observar dicha columna, comprobamos que el **valor máximo absoluto** de toda la muestra es de **0.56** (observación 53), manteniéndose muy *por debajo del umbral crítico de 1*.

Conclusión: Outliers

Ninguno de los valores atípicos observados ejerce una influencia desproporcionada que logre desestabilizar el ajuste global, confirmando que el modelo es altamente robusto.

Selección de Modelo Final: AIC y Criterio

Para determinar la estrategia de modelización definitiva, vamos a emplear un algoritmo de selección por pasos basado en el **Criterio de Información de Akaike** (AIC). Este criterio busca el *equilibrio* más

Table 9: Comparativa Integral de Estrategias de Modelizacion

Variable	Modelo_General	Modelo_AIC
Bondad de Ajuste		
Num. Variables	5.0000	3.0000
Signif. Global (p-valor ANOVA)	0.0000	0.0000
R2 Ajustado	0.7513	0.7528
AIC	-137.5547	-140.2472
Desv. Tipica Residuos (s)	0.1359	0.1355
Coef. Variacion (CV %)	35.1714	35.0634
Cumplimiento de Supuestos		
Normalidad (p-valor SW)	0.5141	0.5362
Homocedasticidad (p-valor BP)	0.1403	0.0537
Autocorrelacion (p-valor DW)	0.1807	0.1936
Max. Distancia Cook	0.5645	0.7161

óptimo entre la **bondad de ajuste** y la **parsimonia**, penalizando por tanto la adición de variables que no aportan un valor predictivo suficiente. Su formula matemática es:

$$AIC = 2k - 2 \ln(\hat{L})$$

Donde k representa el **número de parámetros del modelo** y $\hat{L}$ es el **valor máximo de la función de verosimilitud**. Optamos por esta métrica y descartamos el Criterio de Información Bayesiano (BIC) porque este impone una penalización logarítmica muy elevada en muestras grandes ($k \ln(n)$), lo que en contextos de negocio suele eliminar variables con auténtico valor predictivo.

A continuación, ejecutamos el algoritmo y generamos una tabla para comparar ambos modelos.

Evaluación y Selección del Modelo

El **Modelo AIC** es estadísticamente superior y la nuestra opción definitiva.

Al evaluar las métricas, el algoritmo ha logrado *reducir la complejidad del modelo, pasando de 5 a 3 variables*, logrando un doble beneficio:

- **Mejora la capacidad explicativa:** El R^2 Ajustado sube ligeramente de 0.7513 a 0.7528.
- **Reduce el error:** La desviación típica de los residuos (s) disminuye de 0.1359 a 0.1355.

El valor del AIC confirma esta mejora, descendiendo de -137.5547 a -140.2472. Esto demuestra que el modelo simplificado generado por AIC es más eficiente, evitando el sobreajuste al eliminar variables que no aportaban valor predictivo real y facilitando la interpretación estratégica.

Es completamente posible y válido hacer inferencia en ambos modelos, ya que los dos cumplen con los supuestos fundamentales de los residuos (p-valores > 0.05):

- **Normalidad (Test de Shapiro-Wilk):** Los errores se distribuyen de forma normal (General: $p = 0.5141$, AIC: $p = 0.5362$).
- **Homocedasticidad (Test de Breusch-Pagan):** La varianza es constante a lo largo de las predicciones (General: $p = 0.1403$, AIC: $p = 0.0537$). Aunque el modelo AIC se acerca más al límite de 0.05, lo supera y mantiene el supuesto.
- **Autocorrelación (Test de Durbin-Watson):** Hay independencia en los residuos (General: $p = 0.1807$, AIC: $p = 0.1936$).

Además, la significación global (ANOVA) en ambos modelos es total ($p = 0$), y la influencia máxima medida por la Distancia de Cook se mantiene por debajo del umbral de peligro de 1 (0.5645 y 0.7161, respectivamente). Por tanto, *los intervalos de confianza, los p-valores individuales y las conclusiones estratégicas que se extraigan son matemáticamente sólidas.*

Modelo Final AIC

Tras la búsqueda de una mayor interpretabilidad para nuestro modelo, hemos reducido el número de variables a tres determinando que los factores del número de efectivos policiales y la tasa de divorcios es prescindible paraa nuestro modelo, nos quedamos con las siguientes variables: PctKids2Par, PctUnemployed y NumStreet.

Desafío Extra: El Refinamiento del Modelo y el Efecto Catalizador

¿Es la delincuencia el simple resultado de una suma de factores aislados entre sí, o existe un “efecto catalizador” donde el impacto de un problema social se multiplica exponencialmente al chocar con otro? Hasta ahora, nuestro modelo AIC ha asumido una **relación lineal y aditiva**, sin embargo, para alcanzar un nivel de precisión excelente, debemos preguntarnos *si la estructura del modelo es lo suficientemente robusta* para capturar la complejidad real de nuestros datos.

Optimización Estructural mediante Transformación Box-Cox

Tras el diagnóstico del modelo AIC, observamos que el supuesto de homocedasticidad se cumplía por un *margen muy ajustado* ($p = 0.0537$). Para reforzar la validez de nuestras inferencias y corregir la ligera curvatura observada en los residuos, **aplicamos una transformación Box-Cox**.

Esta técnica busca el parámetro λ óptimo que maximiza la verosimilitud del ajuste, transformando la variable respuesta para **estabilizar la varianza y mejorar la normalidad**. Matemáticamente, la transformación se define como:

$$z_{\lambda,i} = \frac{y_i^\lambda - 1}{\lambda \bar{y}^{\lambda-1}} \quad \text{si } \lambda \neq 0$$

Donde $\bar{y}$ es la media geométrica de las observaciones. Al aplicar este procedimiento, nos aseguramos de que el modelo no solo sea predictivo, sino matemáticamente impecable.

Optimización del parámetro Lambda (Transformación Box-Cox)





Table 10: Resumen del Modelo Lineal (Transformación Box-Cox)

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-0.2290	0.0642	-3.5700	0.0005
PctKids2Par	-0.6675	0.0681	-9.7974	0.0000
PctUnemployed	0.2109	0.0792	2.6645	0.0088
NumStreet	0.1469	0.0667	2.2030	0.0295

```
##
## studentized Breusch-Pagan test
##
## data: modelo_refinado_bc
## BP = 3.0239, df = 3, p-value = 0.388
```

Además realizamos de nuevo la gráfica para observar los cambios que el test nos confirma.



$\text{lm}(\text{ViolentCrimes_bc} \sim \text{PctKids2Par} + \text{PctUnemployed} + \text{NumStreet})$

Términos de Interacción

Una vez optimizada la estructura matemática, procedemos a enriquecer la interpretación estratégica. En sociología criminal, es normal considerar que el *impacto del desempleo* (**PctUnemployed**) no es lineal ni aislado sino que su **efecto puede ser mucho más devastador** en comunidades con estructuras familiares ya debilitadas (**PctKids2Par**). Introducimos un término de interacción para verificar si estas variables “interactúan” entre sí, alterando su peso individual en la predicción. El modelo se expande de la siguiente forma:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 (x_1 \cdot x_2) + \epsilon$$

Donde β_4 representa ese efecto conjunto que va más allá de la simple suma de los factores.

Table 11: Resumen del Modelo Refinado (con Interacción)

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-0.2071	0.0729	-2.8398	0.0053
PctKids2Par	-0.7230	0.1106	-6.5372	0.0000
PctUnemployed	0.1619	0.1105	1.4655	0.1454
NumStreet	0.1587	0.0694	2.2883	0.0239
PctKids2Par:PctUnemployed	0.1445	0.2265	0.6381	0.5246

Nota analítica: El número de condición final (kappa) del modelo es de 949.02.

Conclusión Final:

Tras la evaluación de técnicas más avanzadas para superar las limitaciones del modelo AIC inicial, hemos sacado las siguientes conclusiones:

- **Efectividad de la Transformación Box-Cox:** La aplicación de una transformación de la familia Box-Cox ($\lambda \approx 0.4$) resultó ser la mejora más significativa de esta sección. Logró **estabilizar la varianza de los residuos**, elevando el p-valor del test de Breusch-Pagan de un valor crítico de 0.0537 a un valor sólido 0.4256, garantizando así el cumplimiento del supuesto de homocedasticidad y la fiabilidad de las inferencias. Además, esta optimización de la estructura incrementó la capacidad explicativa del modelo, alcanzando un R^2 ajustado de 0.7602.
- **Análisis de Interacciones y Complejidad:** Exploramos la hipótesis de un efecto multiplicador entre el desempleo y las estructuras familiares, sin embargo, los resultados indicaron que **el término de interacción no es estadísticamente significativo** ($p = 0.6175$). Su inclusión no solo redujo la calidad del ajuste (R^2 ajustado bajó a 0.7587), sino que provocó un aumento innecesario en la inestabilidad numérica, con un número de condición (κ) de 949.01, lo que señala un riesgo de multicolinealidad moderada que no teníamos anteriormente.
- **Selección del Modelo Óptimo:** Siguiendo el principio de parsimonia, que nos dicta la preferencia por el modelo más sencillo que mejor explique los datos, se descarta el modelo con interacciones. El **modelo aditivo con transformación Box-Cox se establece como el definitivo** de la práctica, al ser el más eficiente, robusto ante problemas de varianza y con la mayor capacidad predictiva demostrada.